Análisis de texto

May 21, 2020

0.1 Voy a hacer un analisis de la relacion entre que palabras contienen los tweets y su veracidad. Este analisis abarca, cantidad de palabras, cantidad de caracteres y palabras que aparecen.

Importo las bibliotecas necesarias

[1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.cm as cm
import matplotlib as mpl
import seaborn as sns

from bokeh.plotting import figure, output_file, show
from matplotlib.colors import ListedColormap
from PIL import Image
from wordcloud import WordCloud
from math import log, sqrt

from os import path
from PIL import Image
from wordcloud import WordCloud, STOPWORDS, ImageColorGenerator
import re
```

Defino una paleta de colores

Creo el data frame en base al csv

[2]:
```
tweets = pd.read_csv('csv/train.csv', encoding='latin-1')
```

[3]:
```
cmap = cm.get_cmap('YlOrBr')
```

Analizo como esta formado mi data frame

[4]:
```
tweets.sample(n=3)
```

[4]:
```
          id    keyword   location  \
6663    9551     threat  Ohio, USA
7404   10592    wounded   New York
```

```
4407   6265  hijacking      tokyo

                                                   text  target
6663  The few I warned about .. Were just as I expec…       0
7404  One man fatally shot another wounded on Vermon…       1
4407  #hot  Funtenna: hijacking computers to send da…       0
```

Tanto la columna de location, keyword e id son irrelevantes para este analisis.

[5]:
```
del(tweets['keyword'])
del(tweets['location'])
tweets.sample(n=3)
```

[5]:
```
        id                                                text  target
4111  5842  Hail:The user summons a hailstorm lasting five…       0
6785  9719  @HomeworldGym @thisisperidot D: What? That's a…       0
3266  4691  He came to a land which was engulfed in tribal…       0
```

me guardo cuantos caracteres contiene cada tweet

[6]:
```
tweets['nºcaracteres'] = tweets['text'].str.len()
```

[7]:
```
tweets.sample(n=3)
```

[7]:
```
        id                                                text  target  \
6791  9730  #ModiMinistry Rly tragedy in MP: Some live to …       1
6929  9938  why is it trouble@niallhariss / @simply_vain l…       0
2323  3339  It was finally demolished in the spring of 201…       0

      nºcaracteres
6791            83
6929            75
2323           140
```

[8]:
```
tweets['nºcaracteres'].mean()
```

[8]:
```
101.33613555759885
```

Ahora me interesa separar el texto en palabras.

[9]:
```
tweets['palabras']=tweets['text'].str.split()
```

[10]:
```
tweets.head()
```

[10]:
```
   id                                                text  target  \
0   1  Our Deeds are the Reason of this #earthquake M…       1
```

```
1   4            Forest fire near La Ronge Sask. Canada       1
2   5  All residents asked to 'shelter in place' are …       1
3   6  13,000 people receive #wildfires evacuation or…       1
4   7  Just got sent this photo from Ruby #Alaska as …       1

   nºcaracteres                                          palabras
0            69  [Our, Deeds, are, the, Reason, of, this, #eart…
1            38     [Forest, fire, near, La, Ronge, Sask., Canada]
2           133  [All, residents, asked, to, 'shelter, in, plac…
3            65  [13,000, people, receive, #wildfires, evacuati…
4            88  [Just, got, sent, this, photo, from, Ruby, #Al…
```

Reordeno las columnas para mayor claridad.

[11]:
```
tweets = tweets[['id','text','palabras','nºcaracteres','target']]
```

[12]:
```
tweets.head()
```

[12]:
```
   id                                               text  \
0   1  Our Deeds are the Reason of this #earthquake M…
1   4            Forest fire near La Ronge Sask. Canada
2   5  All residents asked to 'shelter in place' are …
3   6  13,000 people receive #wildfires evacuation or…
4   7  Just got sent this photo from Ruby #Alaska as …

                                        palabras  nºcaracteres  target
0  [Our, Deeds, are, the, Reason, of, this, #eart…            69       1
1     [Forest, fire, near, La, Ronge, Sask., Canada]            38       1
2  [All, residents, asked, to, 'shelter, in, plac…           133       1
3  [13,000, people, receive, #wildfires, evacuati…            65       1
4  [Just, got, sent, this, photo, from, Ruby, #Al…            88       1
```

Me interesa saber cuantas palabras tiene que cada tweet.

[13]:
```
type(tweets['palabras'])
```

[13]:
```
pandas.core.series.Series
```

Guardo la cantidad de palabras en una nueva columna

[14]:
```
lista_auxiliar = []
for i in tweets['palabras']:
    lista_auxiliar.append( len(i) )
```

[15]:
```
tweets['nºpalabras'] = lista_auxiliar
```

[16]:
```
tweets.head()
```

[16]:
```
   id                                                text  \
0   1  Our Deeds are the Reason of this #earthquake M…
1   4             Forest fire near La Ronge Sask. Canada
2   5  All residents asked to 'shelter in place' are …
3   6  13,000 people receive #wildfires evacuation or…
4   7  Just got sent this photo from Ruby #Alaska as …

                                           palabras  nºcaracteres  target  \
0  [Our, Deeds, are, the, Reason, of, this, #eart…            69       1
1     [Forest, fire, near, La, Ronge, Sask., Canada]            38       1
2  [All, residents, asked, to, 'shelter, in, plac…           133       1
3  [13,000, people, receive, #wildfires, evacuati…            65       1
4  [Just, got, sent, this, photo, from, Ruby, #Al…            88       1

   nºpalabras
0          13
1           7
2          22
3           8
4          16
```

Guardo en cada tweet la cantidad de

Reordeno

[17]:
```
tweets = tweets[['id','text','palabras','nºcaracteres','nºpalabras','target']]
```

[18]:
```
tweets.head()
```

[18]:
```
   id                                                text  \
0   1  Our Deeds are the Reason of this #earthquake M…
1   4             Forest fire near La Ronge Sask. Canada
2   5  All residents asked to 'shelter in place' are …
3   6  13,000 people receive #wildfires evacuation or…
4   7  Just got sent this photo from Ruby #Alaska as …

                                           palabras  nºcaracteres  \
0  [Our, Deeds, are, the, Reason, of, this, #eart…            69
1     [Forest, fire, near, La, Ronge, Sask., Canada]            38
2  [All, residents, asked, to, 'shelter, in, plac…           133
3  [13,000, people, receive, #wildfires, evacuati…            65
4  [Just, got, sent, this, photo, from, Ruby, #Al…            88

   nºpalabras  target
```

0	13	1
1	7	1
2	22	1
3	8	1
4	16	1

Ya tengo bastante ordenado el data frame. Procedo a analizar.

Me interesa ver si hay una relacion entre el largo del tweet en palabra y el largo en caracteres. Hago spotter

[19]:
```
tweets_largo = tweets.filter(items=['nºcaracteres', 'nºpalabras', 'target'])
```

[20]:
```
tweets_largo.head()
```

[20]:

	nºcaracteres	nºpalabras	target
0	69	13	1
1	38	7	1
2	133	22	1
3	65	8	1
4	88	16	1

Procedo a hacer un scatter entre ambos.

[21]:
```
color = cmap(0.7)
tweets_largo.plot.scatter('nºcaracteres','nºpalabras', title='Relacion entre␣
↪cantidad de caracteres y palabras',alpha=0.25,figsize=(12,8), color = color);
ax=plt.gca()
ax.set_xlabel('Cantidad de caracteres')
ax.set_ylabel('Cantidad de palabras');
```

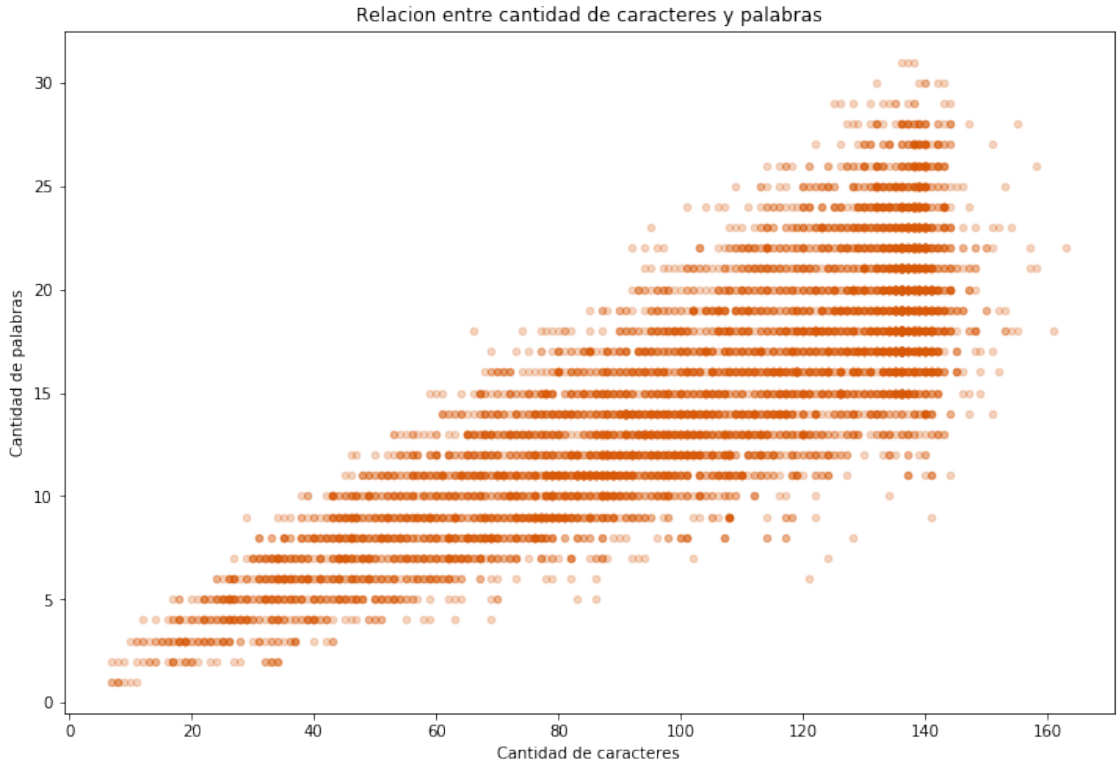

se observa lo esperado

Relacion entre veracidad y largo en caracteres.

[22]:
```
colores = cmap([0.7,0.4])
tweets_verd = tweets_largo[tweets_largo['target']==True]['nºcaracteres']
tweets_falsos = tweets_largo[tweets_largo['target']==False]['nºcaracteres']

promedio = tweets_largo['nºcaracteres'].mean()
promedio_verd = tweets_largo[tweets_largo['target']==1]['nºcaracteres'].mean()
promedio_falsos = tweets_largo[tweets_largo['target']==0]['nºcaracteres'].mean()
plt.figure(figsize=(15,10))
# histogram
plt.hist([tweets_verd, tweets_falsos], bins=50, color=[colores[0], colores[1]],␣
 ↪\
                label=['Tratan sobre un desastre', "No tratan sobre un␣
 ↪desastre"])
plt.vlines(x=promedio, ymin=0, ymax=600, color='black', \
                   alpha=0.6, linestyle = '--', label='Longitud promedio de␣
 ↪todos los tweets')
plt.vlines(x=promedio_verd, ymin=0, ymax=600, color=colores[0], \
```

```
                    alpha=0.6, linestyle = '--', label='Longitud promedio de␣
 ↪tweets sobre un desastre')
plt.vlines(x=promedio_falsos, ymin=0, ymax=600, color=colores[1], \
                    alpha=0.6, linestyle = '--', label='Longitud promedio de␣
 ↪tweets que no son sobre desastre')
plt.xlim(0, 165)
plt.ylim(0, 600)
plt.text(promedio, 450, str(np.round(promedio, 1)), color='black',␣
 ↪fontweight='bold', fontsize=10, rotation=270)
plt.text(promedio_verd, 450, str(np.round(promedio_verd, 1)), color=colores[0],␣
 ↪fontweight='bold', fontsize=10, rotation=270)
plt.text(promedio_falsos, 450, str(np.round(promedio_falsos, 1)),␣
 ↪color=colores[1], fontweight='bold', fontsize=10, rotation=270)
plt.title("Cantidad de tweets según longitud (en caracteres)", weight='bold',␣
 ↪size=20, pad=30)
plt.ylabel("Frecuencia", labelpad=20, weight='bold', size=16)
plt.xlabel("Longitud (en caracteres)",labelpad=20, weight='bold', size=16)
plt.legend(prop={'size': 10})
plt.grid(b=True, axis='y', linestyle='--')
```

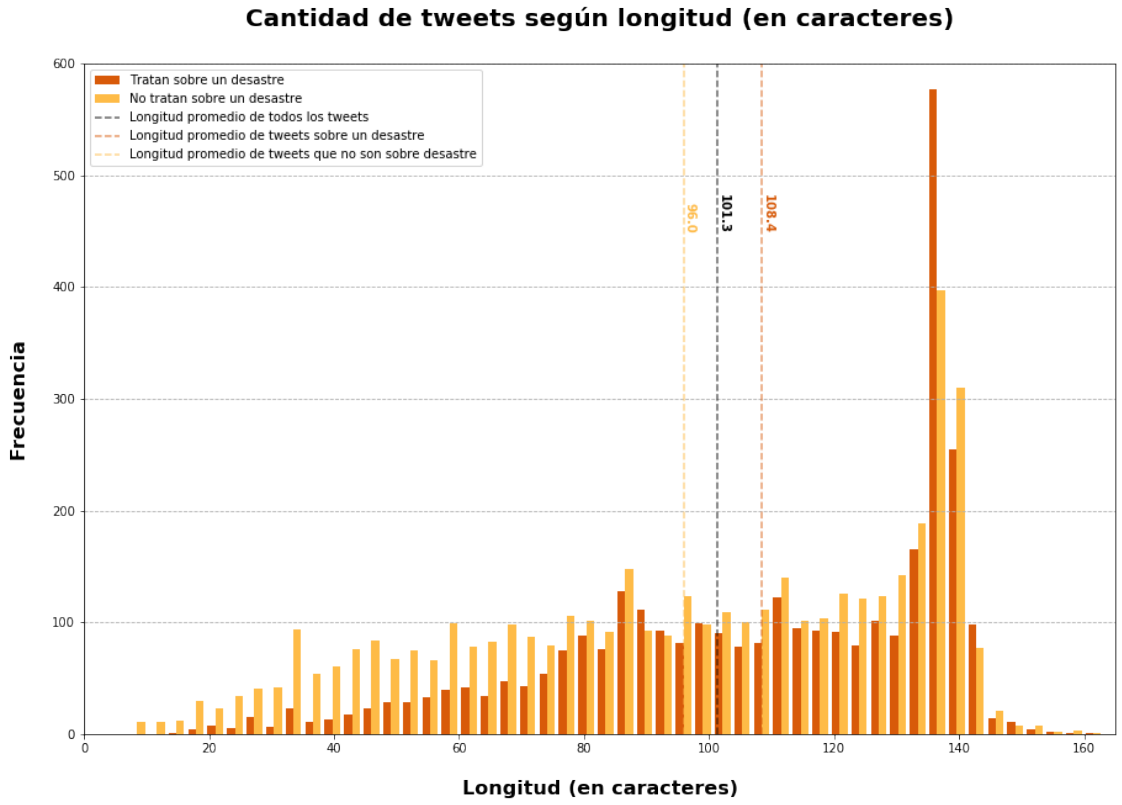

Hago lo mismo pero con palabras

[23]:
```
tweets_largo['intervalo de palabras']=pd.cut(tweets_largo['nºpalabras'],␣
↪bins=[0,5,10,15,20,25,31], include_lowest=True)

tweets_largo
```

[23]:

	nºcaracteres	nºpalabras	target	intervalo de palabras
0	69	13	1	(10.0, 15.0]
1	38	7	1	(5.0, 10.0]
2	133	22	1	(20.0, 25.0]
3	65	8	1	(5.0, 10.0]
4	88	16	1	(15.0, 20.0]
…	…	…	…	…
7608	83	11	1	(10.0, 15.0]
7609	125	20	1	(15.0, 20.0]
7610	65	8	1	(5.0, 10.0]
7611	137	19	1	(15.0, 20.0]
7612	94	13	1	(10.0, 15.0]

[7613 rows x 4 columns]

[24]:
```
tweets_largo = tweets_largo.groupby(['intervalo de palabras']).agg({'target':
↪['mean','count','sum']})
```

[25]:
```
level0 = tweets_largo.columns.get_level_values(0)
level1 = tweets_largo.columns.get_level_values(1)
tweets_largo.columns = level0 + '_' + level1
```

[26]:
```
tweets_largo
```

[26]:

intervalo de palabras	target_mean	target_count	target_sum
(-0.001, 5.0]	0.204604	391	80
(5.0, 10.0]	0.394922	1418	560
(10.0, 15.0]	0.467294	2232	1043
(15.0, 20.0]	0.486148	2238	1088
(20.0, 25.0]	0.401617	1113	447
(25.0, 31.0]	0.239819	221	53

[ ]:
```

```

[27]:
```
tweets_largo.rename({'target_mean': 'ratio_veraces', 'target_count': 'tweets␣
↪totales','target_sum':'Tratan sobre un desastre'}, axis=1, inplace=True)
```

[28]:
```
tweets_largo['No tratan sobre un desastre'] = tweets_largo['tweets totales'] -␣
↪tweets_largo['Tratan sobre un desastre']
```

[29]:
```
tweets_largo
```

[29]:

intervalo de palabras	ratio_veraces	tweets totales	Tratan sobre un desastre	No tratan sobre un desastre
(-0.001, 5.0]	0.204604	391	80	311
(5.0, 10.0]	0.394922	1418	560	858
(10.0, 15.0]	0.467294	2232	1043	1189
(15.0, 20.0]	0.486148	2238	1088	1150
(20.0, 25.0]	0.401617	1113	447	666
(25.0, 31.0]	0.239819	221	53	168

[30]:
```
del tweets_largo['ratio_veraces']
del tweets_largo ['tweets totales']
tweets_largo
```

[30]:

intervalo de palabras	Tratan sobre un desastre	No tratan sobre un desastre
(-0.001, 5.0]	80	311
(5.0, 10.0]	560	858
(10.0, 15.0]	1043	1189
(15.0, 20.0]	1088	1150
(20.0, 25.0]	447	666
(25.0, 31.0]	53	168

[31]:
```
colores = cmap([0.7,0.4])
barra_duo = tweets_largo.plot.bar(color=colores,figsize = (20,10))
barra_duo.set_title("Cantidad de tweets agrupados por el numero de palabras que␣
↪contienen",fontsize = 22)
barra_duo.set_xlabel("Cantidad de palabras", fontsize = 18)
barra_duo.set_ylabel("Cantidad tweets", fontsize = 18)
plt.xticks(fontsize=20, rotation=0)
plt.yticks(fontsize=20)
barra_duo.set_xticklabels(␣
↪["(0,5]","(5,10]","(10,15]","(15,20]","(20,25]","(25,31]"] );
barra_duo.legend(fontsize = 12)
```

[31]:
```
<matplotlib.legend.Legend at 0x7fe835c44950>
```

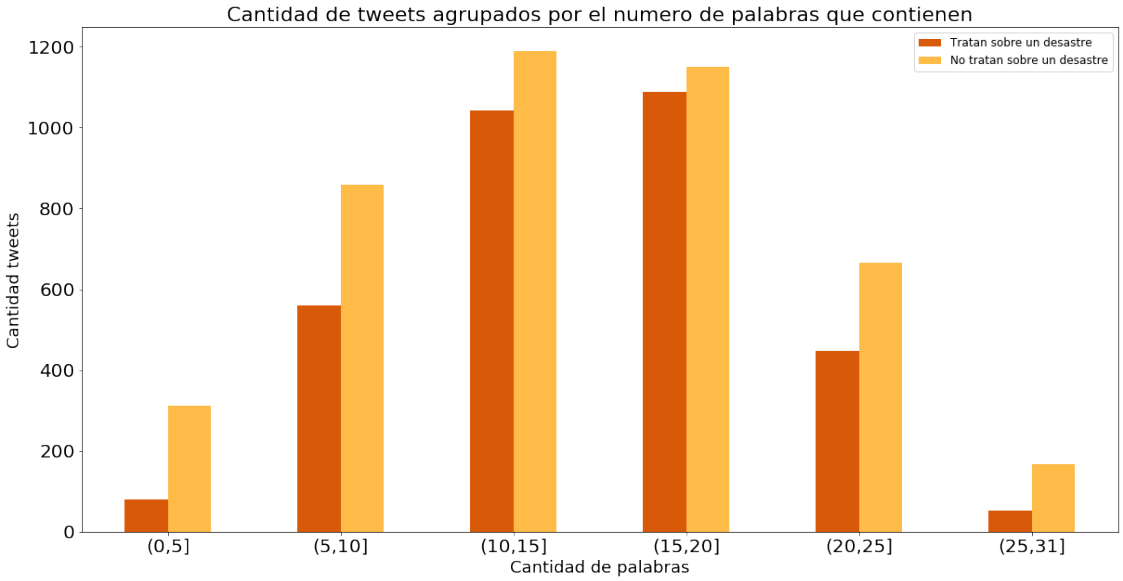

0.2 Palabras que tienen mas ocurrencias en tweets.

Procedo a crear un nuevo dataframe, donde levanto cada palabra junto con su target y id de tweet.

[32]:
```
palabras = tweets.explode('palabras')
del(palabras['text'])
del(palabras['nºcaracteres'])
del(palabras['nºpalabras'])
palabras.rename({'palabras': 'palabra', 'id': 'id_tweet','target':␣
↪'target_tweet' }, axis=1, inplace=True)
palabras.reset_index(inplace = True, drop = True)
palabras.head()
```

[32]:

	id_tweet	palabra	target_tweet
0	1	Our	1
1	1	Deeds	1
2	1	are	1
3	1	the	1
4	1	Reason	1

[33]:
```
palabras.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 113461 entries, 0 to 113460
Data columns (total 3 columns):
 #   Column        Non-Null Count   Dtype
---  ------        --------------   -----
```

```
 0   id_tweet      113461 non-null  int64
 1   palabra       113461 non-null  object
 2   target_tweet  113461 non-null  int64
dtypes: int64(2), object(1)
memory usage: 2.6+ MB
```

En el analisis no voy a discrimnar por mayusculas, paso todo a minuscula.

[34]:
```
palabras['palabra'] = palabras['palabra'].str.lower()
palabras.head()
```

[34]:

	id_tweet	palabra	target_tweet
0	1	our	1
1	1	deeds	1
2	1	are	1
3	1	the	1
4	1	reason	1

Hay casos donde la palabra empieza con un caracter especial, ejemplo de #.

[35]:
```
palabras.iloc[7]
```

[35]:
```
id_tweet                  1
palabra         #earthquake
target_tweet              1
Name: 7, dtype: object
```

Yo quiero eliminar dichos caracteres, ya que en el caso que se encuentren ”“#earthquake” y “earthquake” busco que cuenten como la misma palabra.

[36]:
```
import re
palabras_limpias = []
for palabra in palabras['palabra']:
    palabra_limpia = re.sub('[^A-Za-z0-9]+','', palabra)
    palabras_limpias.append(palabra_limpia)
```

[37]:
```
palabras['palabra']=palabras_limpias
```

[38]:
```
palabras.iloc[7]
```

[38]:
```
id_tweet                1
palabra         earthquake
target_tweet            1
Name: 7, dtype: object
```

Ahora ya borramos los caracteres especiales, el siguiente paso es borrar las palabras que aparecen 2 veces en un tweet. Esto es para que las ocurrencias no cuenten doble.

[39]:
```
palabras.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 113461 entries, 0 to 113460
Data columns (total 3 columns):
 #   Column        Non-Null Count   Dtype 
---  ------        --------------   ----- 
 0   id_tweet      113461 non-null  int64 
 1   palabra       113461 non-null  object
 2   target_tweet  113461 non-null  int64 
dtypes: int64(2), object(1)
memory usage: 2.6+ MB
```

[40]:
```
palabras.drop_duplicates(subset=['palabra','id_tweet'], keep="first", inplace =␣
↪True)
palabras.reset_index(inplace = True, drop = True)
```

[41]:
```
palabras.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 107617 entries, 0 to 107616
Data columns (total 3 columns):
 #   Column        Non-Null Count   Dtype 
---  ------        --------------   ----- 
 0   id_tweet      107617 non-null  int64 
 1   palabra       107617 non-null  object
 2   target_tweet  107617 non-null  int64 
dtypes: int64(2), object(1)
memory usage: 2.5+ MB
```

Ya fueron eliminadas las palabras repetidas de cada tweet, todo listo para el analisis

[42]:
```
agrupadas=palabras.groupby(['palabra']).agg({'target_tweet':
↪['mean','count','sum']})
agrupadas.sample(3)
```

[42]:

	target_tweet		
	mean	count	sum
palabra			
httptcol9ekhnkbar	0.00	1	0
arts	0.25	4	1
httptconjrjxqbjr4	0.00	1	0

[43]:
```
agrupadas.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 22365 entries,  to zzzz
Data columns (total 3 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   (target_tweet, mean)   22365 non-null  float64
 1   (target_tweet, count)  22365 non-null  int64
 2   (target_tweet, sum)    22365 non-null  int64
dtypes: float64(1), int64(2)
memory usage: 698.9+ KB
```

En este caso sum son las veces que la palabra aparece en tweets veridicos.(ya que el true esta representado con un uno)

Aplano el level de las columnas.

[44]:
```
level0 = agrupadas.columns.get_level_values(0)
level1 = agrupadas.columns.get_level_values(1)
agrupadas.columns = level0 + '_' + level1
```

[45]:
```
agrupadas.sample(3)
```

[45]:

palabra	target_tweet_mean	target_tweet_count	target_tweet_sum
harris	1.0	1	1
tittie	0.0	1	0
httptcoqeihvn3dnq	0.0	1	0

Renombro

[46]:
```
agrupadas.rename({'target_tweet_mean': 'porcentaje_veraces',␣
↪'target_tweet_count': 'apariciones_totales','target_tweet_sum':
↪'apariciones_veraces'}, axis=1, inplace=True)
```

[47]:
```
agrupadas.sample(3)
```

[47]:

palabra	porcentaje_veraces	apariciones_totales	apariciones_veraces
1945	1.0	6	6
gig	0.0	2	0
httptcozsqm8ihe1k	0.0	1	0

Transformo el ratio en porcentaje

[48]:
```
agrupadas['porcentaje_veraces'] = agrupadas['porcentaje_veraces']*100
```

[49]:
```
agrupadas.sample(3)
```

[49]:
```
                    porcentaje_veraces  apariciones_totales  \
palabra
httptcoethgagpy5g             0.000000                    1
0                            66.666667                    9
executing                   100.000000                    2

                    apariciones_veraces
palabra
httptcoethgagpy5g                     0
0                                     6
executing                             2
```

Agrego una columna de apariciones_falaces

[50]:
```
agrupadas['apariciones_falaces'] = (agrupadas['apariciones_totales'] -␣
↪agrupadas['apariciones_veraces'])
```

[51]:
```
agrupadas.sample(3)
```

[51]:
```
                    porcentaje_veraces  apariciones_totales  \
palabra
httptcorb02svlppu                  0.0                    1
hinton                           100.0                    3
citrus                           100.0                    1

                    apariciones_veraces  apariciones_falaces
palabra
httptcorb02svlppu                     0                    1
hinton                                3                    0
citrus                                1                    0
```

Considero que las palabras que aparecen menos del 0.2% de los tweets son irrelevantes para este analisis. Suelen ser 'one hit'

[52]:
```
agrupadas.info() #palabras previo a filtrar
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 22365 entries,  to zzzz
Data columns (total 4 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   porcentaje_veraces   22365 non-null  float64
```

```
 1   apariciones_totales  22365 non-null  int64
 2   apariciones_veraces  22365 non-null  int64
 3   apariciones_falaces  22365 non-null  int64
dtypes: float64(1), int64(3)
memory usage: 873.6+ KB
```

[53]:
```
minimo_de_ocurrencias = (0.2/100)*len(tweets.index)
minimo_de_ocurrencias
```

[53]:
```
15.226
```

[54]:
```
agrupadas = agrupadas.
↪loc[agrupadas[('apariciones_totales')]>minimo_de_ocurrencias,:]
```

[55]:
```
agrupadas.info() #palabras despues de filtrar
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1038 entries,  to zone
Data columns (total 4 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   porcentaje_veraces   1038 non-null   float64
 1   apariciones_totales  1038 non-null   int64
 2   apariciones_veraces  1038 non-null   int64
 3   apariciones_falaces  1038 non-null   int64
dtypes: float64(1), int64(3)
memory usage: 40.5+ KB
```

[56]:
```
#### Cuales son las palabras que mas se repiten?
```

[57]:
```
agrupadas.sort_values(by=['apariciones_totales'], ascending=[False], inplace =␣
↪True)
```

[58]:
```
agrupadas.head(7)
```

[58]:

palabra	porcentaje_veraces	apariciones_totales	apariciones_veraces	apariciones_falaces
the	42.331542	2419	1024	
in	57.543466	1783	1026	
a	42.270939	1779	752	
to	39.976484	1701	680	
	41.977501	1689	709	
of	50.364520	1646	829	
and	36.434715	1279	466	

```
the                    1395
in                      757
a                      1027
to                     1021
                        980
of                      817
and                     813
```

[59]:
```
####dropeo los espacio en blanco
agrupadas = agrupadas.drop('')
agrupadas.head(100)
len(agrupadas)
```

[59]:
```
1037
```

Grafico las 30 palabras mas repetidas

[60]:
```
agrupadas_mas_repetidas = agrupadas.head(30)
```

[61]:
```
saltos = np.linspace(0.3, 0.9, 30)
colores = cmap(saltos)

maximo = agrupadas_mas_repetidas['apariciones_totales'].max()

grafico = agrupadas_mas_repetidas.sort_values("apariciones_totales").
 ↪plot(kind='barh', figsize=(14,12), y ='apariciones_totales', color=colores,␣
 ↪width=0.75, fontsize = 18)

plt.xticks(np.arange(0, maximo+1, 100), rotation=35,fontsize=14,ha='right')
plt.tick_params(axis='y', length=0)

grafico.spines['right'].set_visible(False)
grafico.spines['top'].set_visible(False)
grafico.spines['left'].set_visible(False)
grafico.spines['bottom'].set_visible(False)

lineas = grafico.get_xticks()
for i in lineas:
      grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')

grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)

plt.title("30 palabras más repetidas", weight='bold', size=20, pad=15)
grafico.legend(fontsize = 15)
plt.gca().get_legend().remove()
```

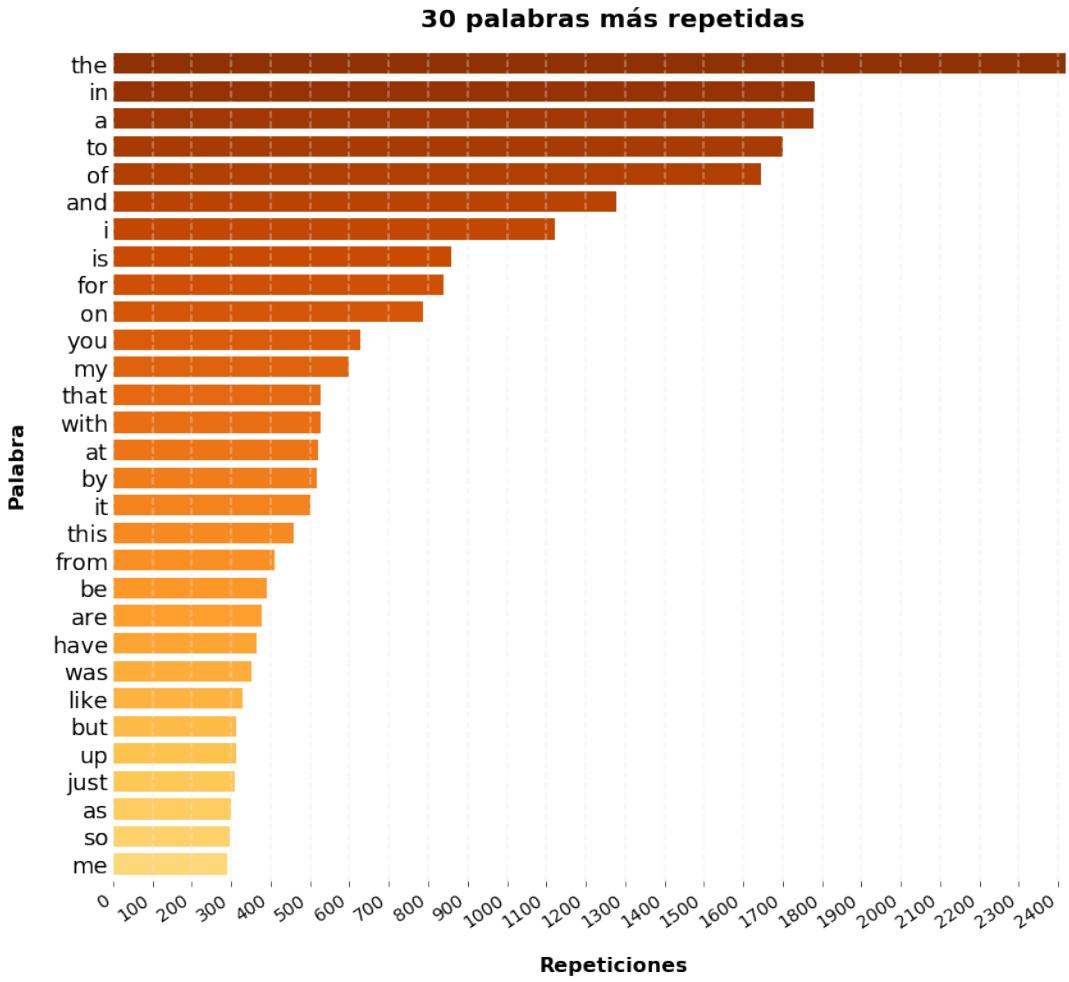

[62]:
```
agrupadas_sin_preposiciones = agrupadas.copy()
```

[63]:
```
agrupadas_sin_preposiciones.head()
```

[63]:

palabra	porcentaje_veraces	apariciones_totales	apariciones_veraces	apariciones_falaces
the	42.331542	2419	1024	1395
in	57.543466	1783	1026	757
a	42.270939	1779	752	1027
to	39.976484	1701	680	
of	50.364520	1646	829	

```
to                      1021
of                       817
```

[64]:
```
stopwords = list(STOPWORDS)
palabras = agrupadas_sin_preposiciones.index.tolist()
```

[65]:
```
es_stop = []
for palabra in palabras:
    es_stop.append( palabra not in stopwords )

agrupadas_sin_preposiciones = agrupadas_sin_preposiciones.iloc[es_stop]
agrupadas_sin_preposiciones.head()
```

[65]:
```
         porcentaje_veraces  apariciones_totales  apariciones_veraces  \
palabra
im                18.996416                  279                   53
amp               35.315985                  269                   95
will              30.081301                  246                   74
fire              70.689655                  232                  164
new               25.000000                  220                   55

         apariciones_falaces
palabra
im                       226
amp                      174
will                     172
fire                      68
new                      165
```

[66]:
```
agrupadas_sin_preposiciones = agrupadas_sin_preposiciones.head(30) ### me quedo␣
↪con las primeras 30
agrupadas_sin_preposiciones.head(2)
```

[66]:
```
         porcentaje_veraces  apariciones_totales  apariciones_veraces  \
palabra
im                18.996416                  279                   53
amp               35.315985                  269                   95

         apariciones_falaces
palabra
im                       226
amp                      174
```

sin preposiciones mas repetidas

[67]:
```
saltos = np.linspace(0.3, 0.9, 30)
colores = cmap(saltos)

maximo = agrupadas_sin_preposiciones['apariciones_totales'].max()

grafico = agrupadas_sin_preposiciones.sort_values("apariciones_totales").
 ↪plot(kind='barh', figsize=(14,12), y ='apariciones_totales', color=colores,␣
 ↪width=0.75, fontsize = 18)

plt.xticks(np.arange(0, maximo+1, 10), rotation=35,fontsize=14,ha='right')
plt.tick_params(axis='y', length=0)

grafico.spines['right'].set_visible(False)
grafico.spines['top'].set_visible(False)
grafico.spines['left'].set_visible(False)
grafico.spines['bottom'].set_visible(False)

lineas = grafico.get_xticks()
for i in lineas:
      grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')

grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)

plt.title("30 palabras más repetidas (sin preposiciones ni artículos)",␣
 ↪weight='bold', size=20, pad=15)
grafico.legend(fontsize = 15)
plt.gca().get_legend().remove()
```

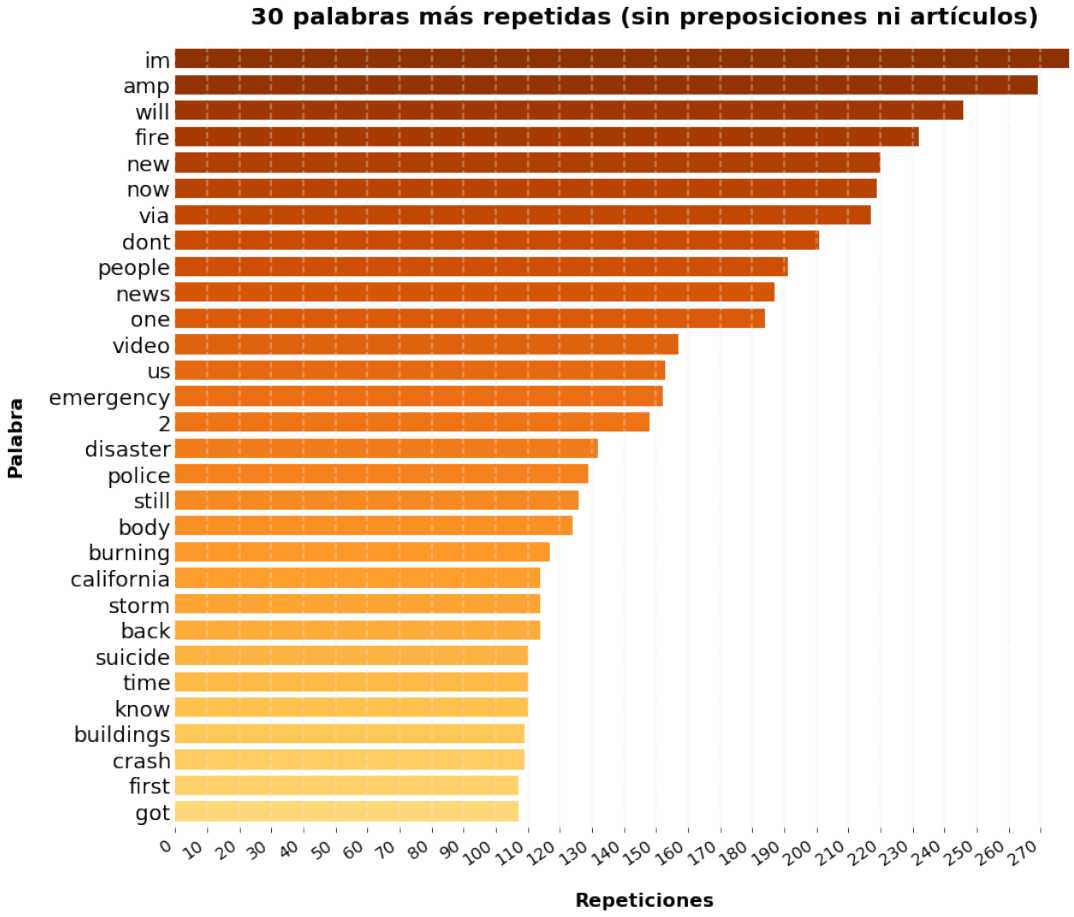

veracidad de las palabras mas repetidas.

[68]:
```
saltos = np.linspace(0.4, 0.7, 30)
colores = cmap(saltos)

#maximo = agrupadas_mas_repetidas['apariciones_totales'].max()
maximo = 100

grafico = agrupadas_mas_repetidas.sort_values("porcentaje_veraces").
↪plot(kind='barh', figsize=(14,12), y ='porcentaje_veraces', color=colores,␣
↪width=0.75, fontsize = 18)

plt.xticks(np.arange(0, maximo+1, 5), rotation=35,fontsize=14,ha='right')
plt.tick_params(axis='y', length=0)

grafico.spines['right'].set_visible(False)
grafico.spines['top'].set_visible(False)
grafico.spines['left'].set_visible(False)
```

```
grafico.spines['bottom'].set_visible(False)

lineas = grafico.get_xticks()
for i in lineas:
      grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')

grafico.set_xlabel("Veracidad", labelpad=20, weight='bold', size=16)
grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)

plt.title("Veracidad de las 30 palabras más repetidas", weight='bold', size=20,␣
 ↪pad=15)
grafico.legend(fontsize = 15)
plt.gca().get_legend().remove()
```

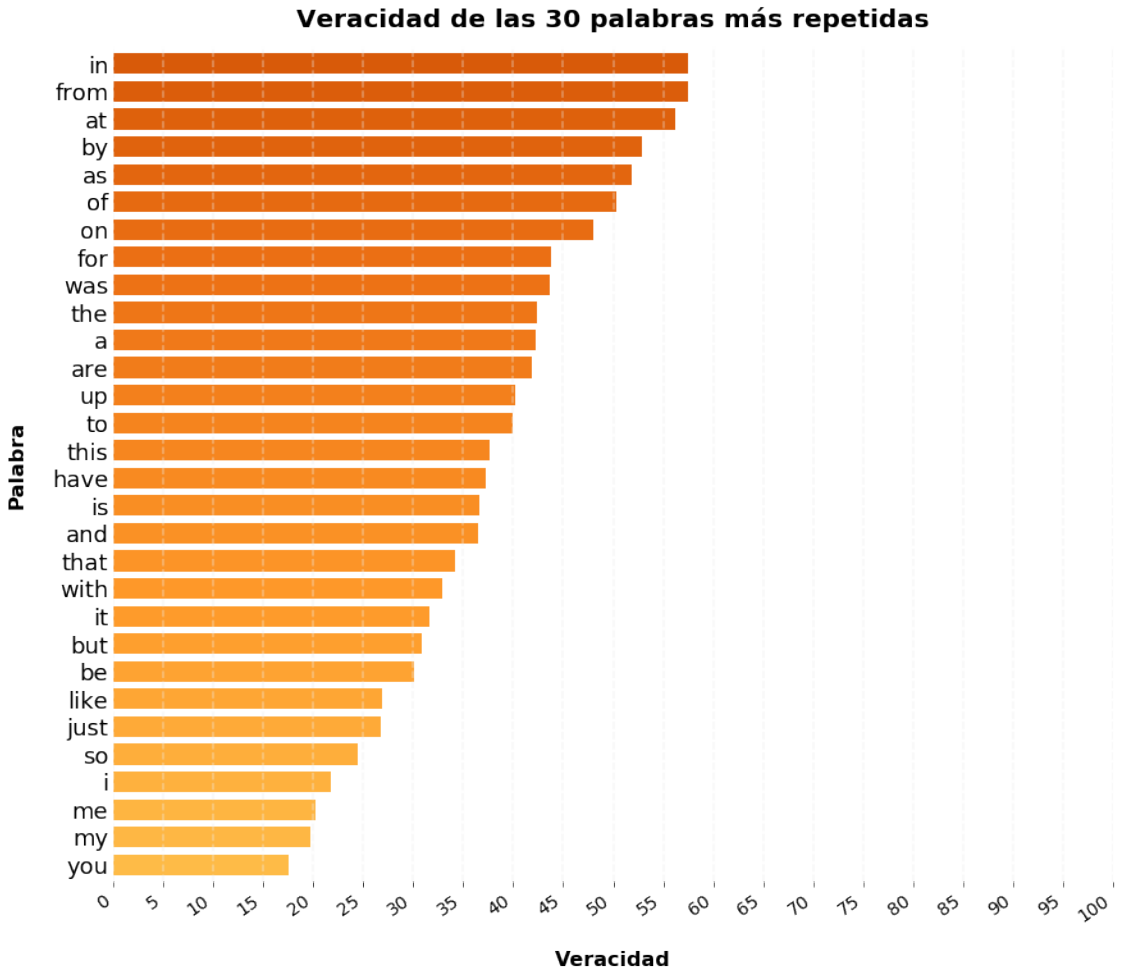

veracidad de mas repetidas sin preposiciones

[69]:
```
saltos = np.linspace(0.4, 0.7, 30)
colores = cmap(saltos)

#maximo = agrupadas_mas_repetidas['apariciones_totales'].max()
maximo = 100

grafico = agrupadas_sin_preposiciones.sort_values("porcentaje_veraces").
 ↪plot(kind='barh', figsize=(14,12), y ='porcentaje_veraces', color=colores,␣
 ↪width=0.75, fontsize = 18)

plt.xticks(np.arange(0, maximo+1, 5), rotation=35,fontsize=14,ha='right')
plt.tick_params(axis='y', length=0)

grafico.spines['right'].set_visible(False)
grafico.spines['top'].set_visible(False)
grafico.spines['left'].set_visible(False)
grafico.spines['bottom'].set_visible(False)

lineas = grafico.get_xticks()
for i in lineas:
      grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')

grafico.set_xlabel("Veracidad", labelpad=20, weight='bold', size=16)
grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)

plt.title("Veracidad de las 30 palabras más repetidas (sin preposiciones ni␣
 ↪artículos)", weight='bold', size=20, pad=15)
grafico.legend(fontsize = 15)
plt.gca().get_legend().remove()
```

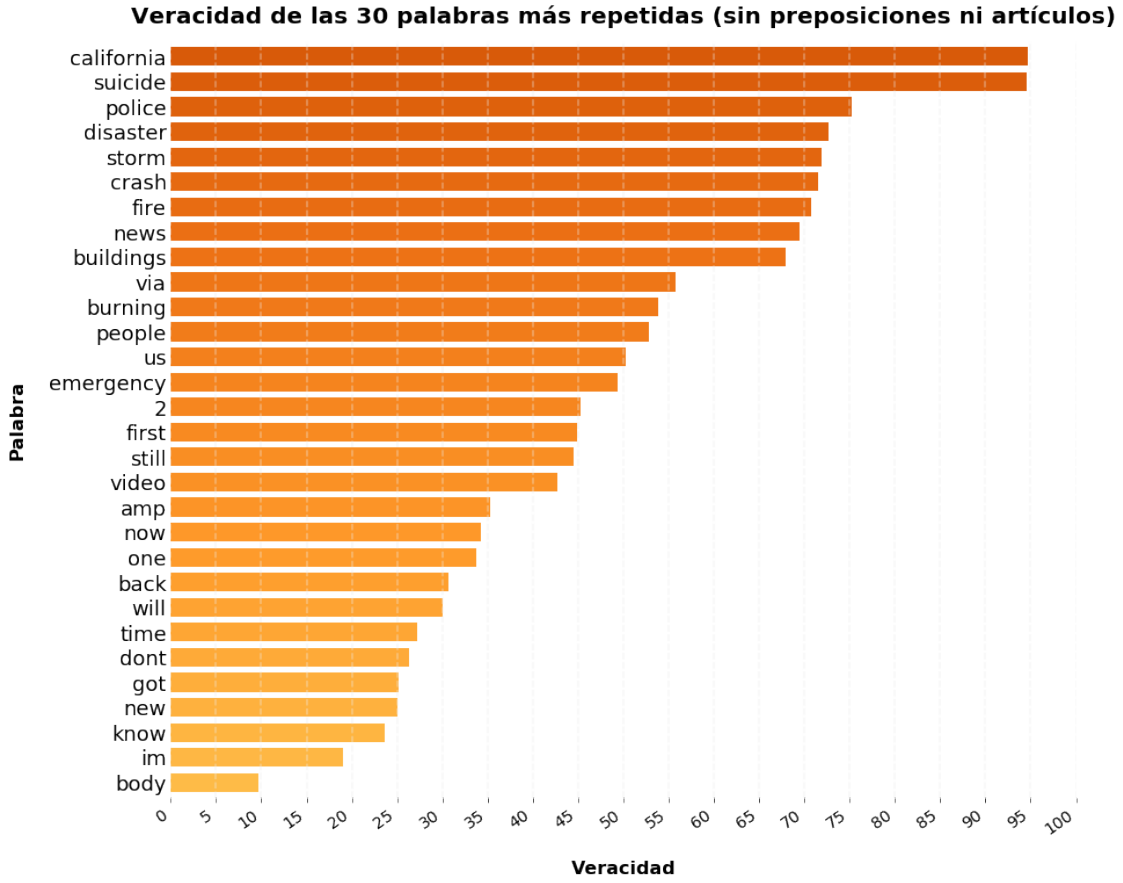

Ordeno segun porcentaje de veracidad y apariciones totales.

[70]:
```
agrupadas.sort_values(by=['porcentaje_veraces', 'apariciones_totales'],␣
↪ascending=[False, False], inplace = True)
```

[71]:
```
agrupadas.head()
```

[71]:

palabra	porcentaje_veraces	apariciones_totales	apariciones_veraces	apariciones_falaces
mh370	100.0	69	69	0
northern	100.0	64	64	0
debris	100.0	49	49	
severe	100.0	44	44	
derailment	100.0	40	40	

```
debris                      0
severe                      0
derailment                  0
```

Reordeno columnas

[72]:
```
agrupadas = agrupadas[['apariciones_veraces', 'apariciones_falaces',␣
↪'apariciones_totales', 'porcentaje_veraces']]
agrupadas.head()
```

[72]:
```
            apariciones_veraces  apariciones_falaces  apariciones_totales  \
palabra
mh370                        69                    0                   69
northern                     64                    0                   64
debris                       49                    0                   49
severe                       44                    0                   44
derailment                   40                    0                   40

            porcentaje_veraces
palabra
mh370                    100.0
northern                 100.0
debris                   100.0
severe                   100.0
derailment               100.0
```

0.2.1 Me armo mi array de colores

[73]:
```
saltos = np.linspace(0.3, 0.7, 20)
colores = cmap(saltos)
```

Como se distrubuyen las palabras a lo largo del porcentaje de veracidad? donde se concentran mas?

[74]:
```
plt.figure(figsize= (16,12) )
color = tuple( colores[19] )
fig=plt.figure()
ax = fig.add_subplot(111)
plt.xlim(0,100)
plt.title('Densidad de  palabras en funcion de % de veracidad␣
↪',fontsize=16,fontweight='bold')
ax.set_xlabel('% de veracidad')
agrupadas['porcentaje_veraces'].plot.kde(color = color , figsize=(10, 5));
```

```
<Figure size 1152x864 with 0 Axes>
```

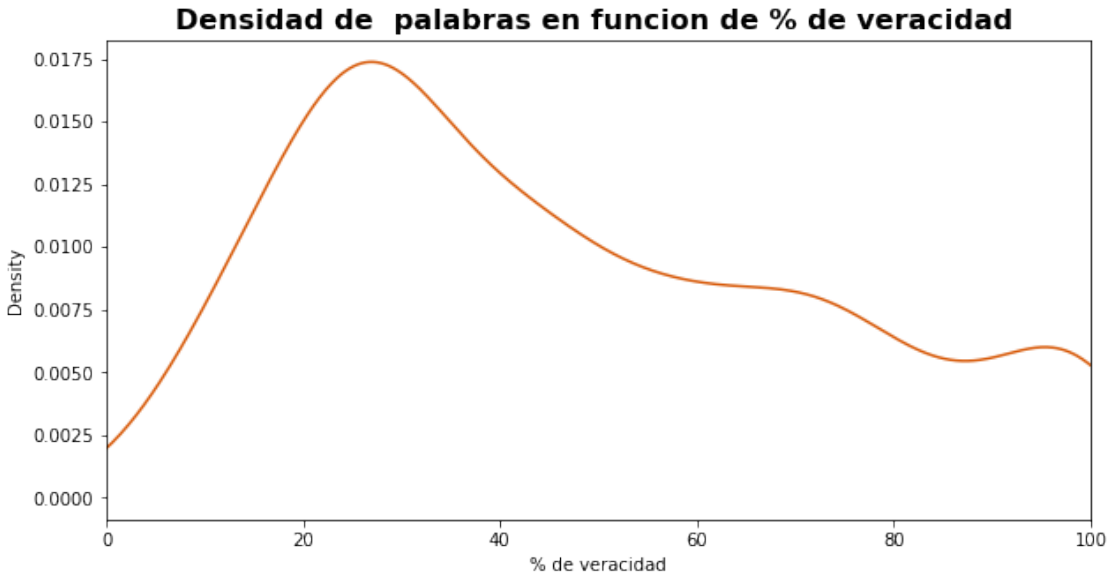

[75]:
```
plt.figure(figsize=(10,10))
n, bins, patches = plt.hist(agrupadas["porcentaje_veraces"], bins=10, color="c")
hist_porcentajes = plt.gca()

for i,p in enumerate(patches):
    plt.setp(p, "facecolor", colores[i+3])

plt.xticks(np.arange(0, 100+1, 10.0))
plt.yticks(np.arange(0, 210+1, 10.0))
plt.tick_params(axis='y', length=0)

hist_porcentajes.spines['right'].set_visible(False)
hist_porcentajes.spines['top'].set_visible(False)
hist_porcentajes.spines['left'].set_visible(False)

lineas = hist_porcentajes.get_yticks()
for i in lineas:
      hist_porcentajes.axhline(y=i, linestyle='--', alpha=0.4, color='#eeeeee')

hist_porcentajes.set_xlabel("Porcentaje de Veracidad", labelpad=20,␣
 ↪weight='bold', size=16)
hist_porcentajes.set_ylabel("Cantidad de Palabras", labelpad=20, weight='bold',␣
 ↪size=16)

plt.title("Cantidad de palabras por porcentaje de veracidad", weight='bold',␣
 ↪size=20, pad=30)
```

[75]: Text(0.5, 1.0, 'Cantidad de palabras por porcentaje de veracidad')

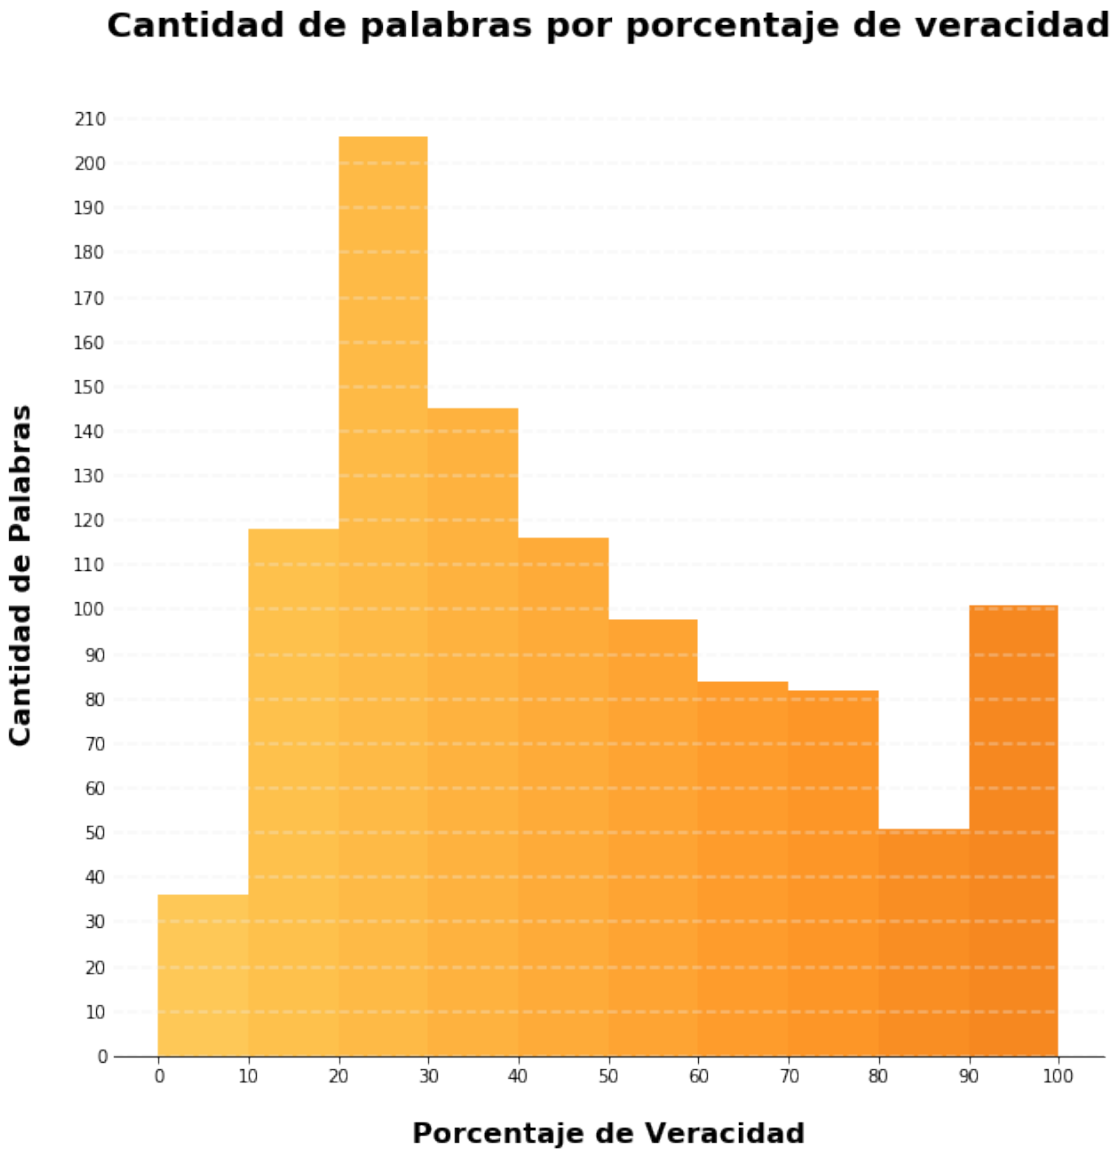

Con esto se puede observar que en aproximadamente entre el 20% 30% de la veracidad es donde se asocian mas palabras diferentes. Esto es debido a que suelen haber mas tweets verdaderos que falsos, por lo tanto es esperable que el pico este desviado hacia la izquierda del 50%.

Ahora veo como se distribuyen las palabras en funciona su % de veracidad y sus repeticiones.

[76]:
```
agrupadas.head(100)
```

[76]:
```
            apariciones_veraces  apariciones_falaces  apariciones_totales  \
palabra
mh370                        69                    0                   69
northern                     64                    0                   64
debris                       49                    0                   49
severe                       44                    0                   44
derailment                   40                    0                   40
…                           …                     …                   …
plane                        30                    3                   33
officer                      20                    2                   22
pm                           58                    6                   64
picking                      19                    2                   21
heavy                        18                    2                   20

            porcentaje_veraces
palabra
mh370               100.000000
northern            100.000000
debris              100.000000
severe              100.000000
derailment          100.000000
…                          …
plane                90.909091
officer              90.909091
pm                   90.625000
picking              90.476190
heavy                90.000000

[100 rows x 4 columns]
```

Se puede observar que hay mucha palabras con el mas de 0.2 % de apariciones que tienen 100 de veracidad, observo como se relaciona la veracidad una palabra en relacion con la cantidad de repeticiones de la misma.

[77]:
```
agrupadas.plot.scatter('porcentaje_veraces','apariciones_totales',␣
↪title='Relacion entre veracidad y apariciones',alpha=0.25,figsize=(12,8),␣
↪color = color);
ax=plt.gca()
ax.set_ylabel('Cantidad de tweets donde aparece la palabra')
ax.set_xlabel('Porcentaje de veracidad');
```

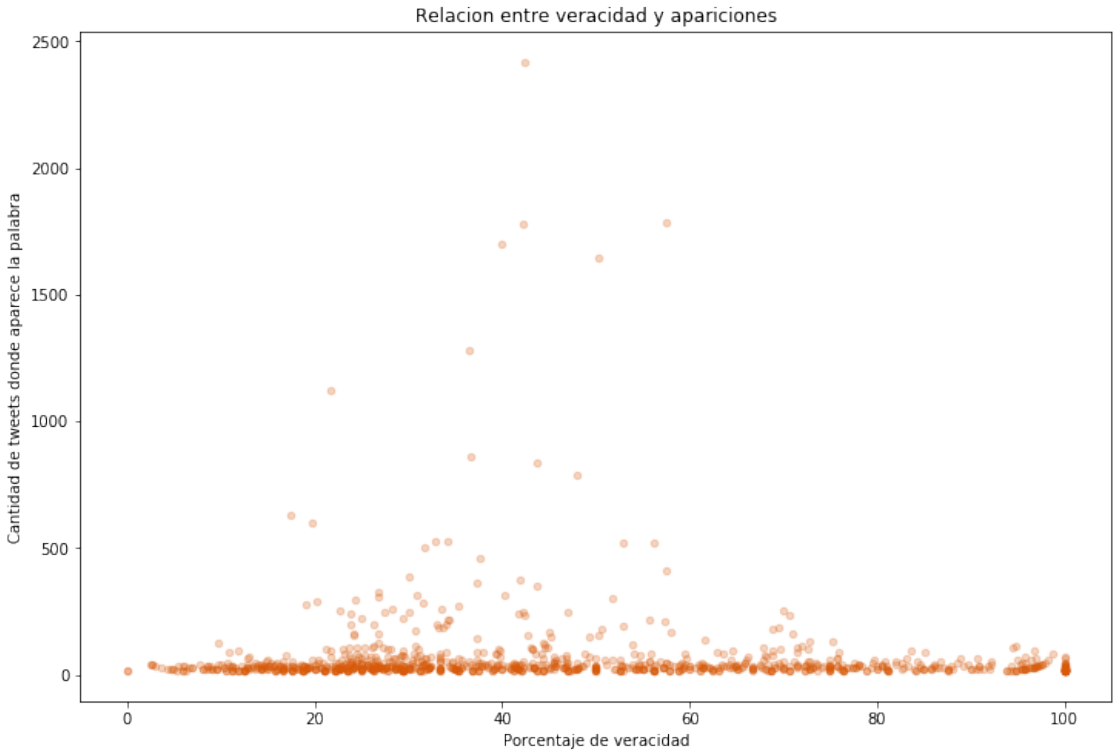

Parece haber muy pocas palabras con mas de 500 apariciones, y como es obvio las que lo cumplen tienden a rondar el 50% de veracidad. Elimino estas al no tener relevancia en el analisis.

[78]:
```
agrupadas_short = agrupadas.loc[agrupadas[('apariciones_totales')]<500,:]
```

[79]:
```
agrupadas_short.plot.scatter('porcentaje_veraces','apariciones_totales',␣
↪title='Relacion entre apariciones y veracidad (filtrando en 500)',alpha=0.
↪25,figsize=(12,8), color = color);
ax=plt.gca();
ax=plt.gca()
ax.set_ylabel('Cantidad de tweets donde aparece la palabra')
ax.set_xlabel('Porcentaje de veracidad');
```

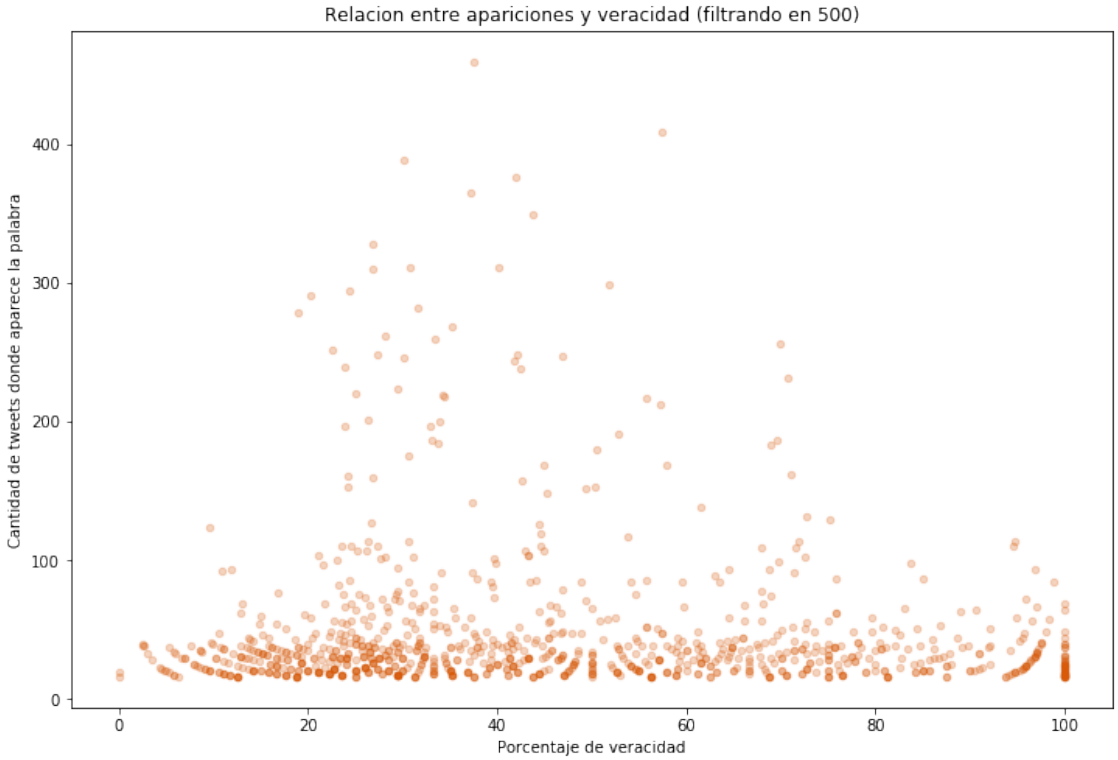

Se sigue demostrando una gran acumulacion debajo de las 100 apariciones, vuelvo a filtrar.

[80]:
```
agrupadas_short = agrupadas.loc[agrupadas[('apariciones_totales')]<100,:]
```

[81]:
```
agrupadas_short.plot.scatter('porcentaje_veraces','apariciones_totales',␣
↪title='Relacion entre apariciones y veracidad (filtrando en 100)',alpha=0.
↪25,figsize=(12,8), color = color);
ax=plt.gca()
ax.set_ylabel('Cantidad de tweets donde aparece la palabra')
ax.set_xlabel('Porcentaje de veracidad');
```

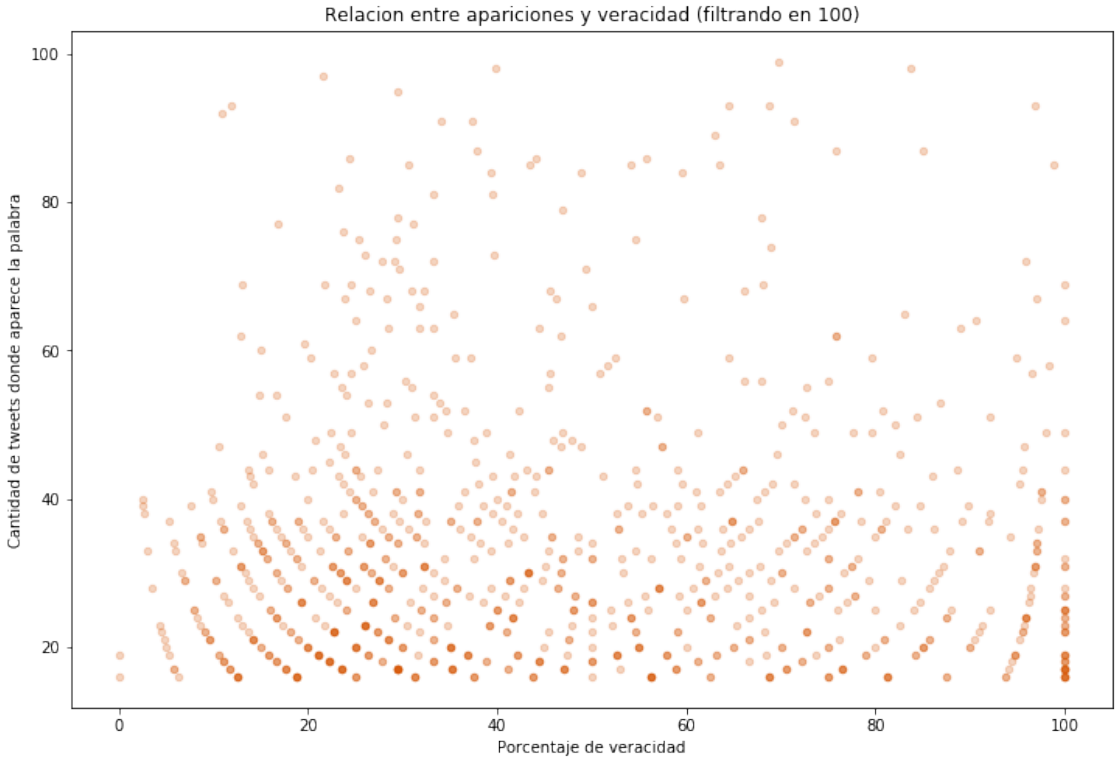

Como es de esperarse vemos una agrupacion de muchas palabras en 100% de veracidad, esto se debe a que la muestra no es suficientemente grande.

Luego se puede observar que al buscar palabras con mayo numero de apariciones, el procentaje de veracidad se encuentra alrededor del 50%.

Cantidad de apariciones con 100% de veracidad

[82]:
```
agrupadas_short = agrupadas.loc[agrupadas[('porcentaje_veraces')]==100,:]
```

[83]:
```
saltos = np.linspace(0.2, 0.9, 50)
colores = cmap(saltos)

maximo = agrupadas_short['apariciones_totales'].max()

grafico = agrupadas_short.sort_values("apariciones_totales").plot(kind='barh',␣
↪figsize=(14,12), y ='apariciones_totales', color=colores, width=0.75,␣
↪fontsize = 18)

plt.xticks(np.arange(0, maximo+1, 5))
plt.tick_params(axis='y', length=0)
```

```
grafico.spines['right'].set_visible(False)
grafico.spines['top'].set_visible(False)
grafico.spines['left'].set_visible(False)
grafico.spines['bottom'].set_visible(False)

lineas = grafico.get_xticks()
for i in lineas:
      grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')

grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)

plt.title("Apariciones de palabras con 100% de veracidad", weight='bold',␣
 ↪size=20, pad=15)
grafico.legend(fontsize = 15)
plt.gca().get_legend().remove()
```

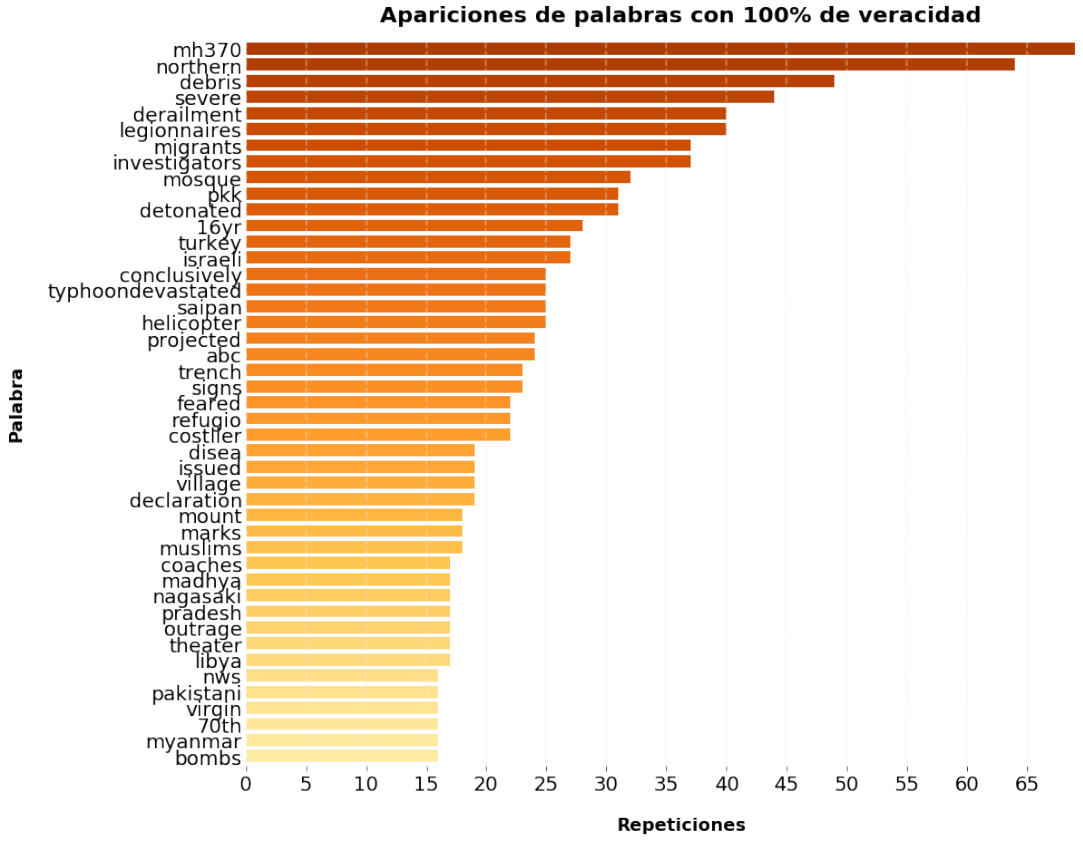

[ ]:

Quiero graficar todas las palabras que tienen por lo menos un 90% de veracidad, me parece algo interesante.

[84]:
```
agrupadas_short = agrupadas.loc[agrupadas[('porcentaje_veraces')]>=90,:]
agrupadas_short.head()
```

[84]:

palabra	apariciones_veraces	apariciones_falaces	apariciones_totales	porcentaje_veraces
mh370	69	0	69	100.0
northern	64	0	64	100.0
debris	49	0	49	100.0
severe	44	0	44	100.0
derailment	40	0	40	100.0

[85]:
```
agrupadas_short.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 101 entries, mh370 to east
Data columns (total 4 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   apariciones_veraces  101 non-null    int64
 1   apariciones_falaces  101 non-null    int64
 2   apariciones_totales  101 non-null    int64
 3   porcentaje_veraces   101 non-null    float64
dtypes: float64(1), int64(3)
memory usage: 3.9+ KB
```

Tengo 100 items, un wordcloud es una buena idea. El tamaño va asociado a la cantidad de repeticiones, el color a el % de veracidad.

[86]:
```
color_wordcloud = cmap(np.linspace(0.4, .9,101))
colores_rgb = ()
for i in color_wordcloud:
    #convierto rgba en rgb
    aux = list(i)
    del aux[3]
    aux = (int(x * 255) for x in aux)
    aux =tuple(aux)
    colores_rgb = colores_rgb + (aux,)
```

[87]:
```
#cosa de mandinga, no tocar
def my_tf_color_func_mayor_veracidad(dictionary):
  def my_tf_color_func_inner(word, font_size, position, orientation,␣
 ↪random_state=None, **kwargs):
    return colores_rgb[int ( (dictionary[word]-90)*10) ]
  return my_tf_color_func_inner
```

[88]:
```
indices = list(agrupadas_short.index)
valores = list(agrupadas_short['apariciones_totales'])
todas_las_palabras = list()
```

[89]:
```
for i in range( len(indices) ):
    for j in range ( valores[i] ):
        todas_las_palabras.append(indices[i])
```

[90]:
```
todas_las_palabras = pd.Series(todas_las_palabras).to_string()
```

[91]:
```
mask = np.array(Image.open("../TP1-Organizacion-de-Datos/imagenes/ovalo.png"))
```

[92]:
```
keys = {}
veracidades = agrupadas_short['porcentaje_veraces'].tolist()

for i in range(len(indices)):
    keys[indices[i]] = veracidades[i]
```

[93]:
```
plt.figure(figsize= (16,12) )
wordcloud = WordCloud(font_path='../fonts/truetype/ubuntu/Ubuntu-M.
 ↪ttf',collocations=False, colormap=cmap, \
                      relative_scaling=0.5, background_color='white',␣
 ↪width=800, height=200, \
                      color_func=my_tf_color_func_mayor_veracidad(keys),␣
 ↪normalize_plurals=False, mask=mask, prefer_horizontal=0.5).
 ↪generate(todas_las_palabras)

topes = mpl.colors.Normalize(vmin=90, vmax=100)
cmap_wordcloud = ListedColormap(cmap(np.linspace(0.4, 0.9, 256)))

plt.imshow(wordcloud, interpolation='bilinear')
plt.colorbar(cm.ScalarMappable(norm=topes, cmap=cmap_wordcloud),␣
 ↪label='Veracidad (%)', \
             orientation='horizontal', shrink=0.75, pad=0.05)
plt.axis("off")
plt.title("Palabras con mas de 90% de veracidad ", weight='bold', size=20,␣
 ↪pad=30)
```

```
plt.show()
```

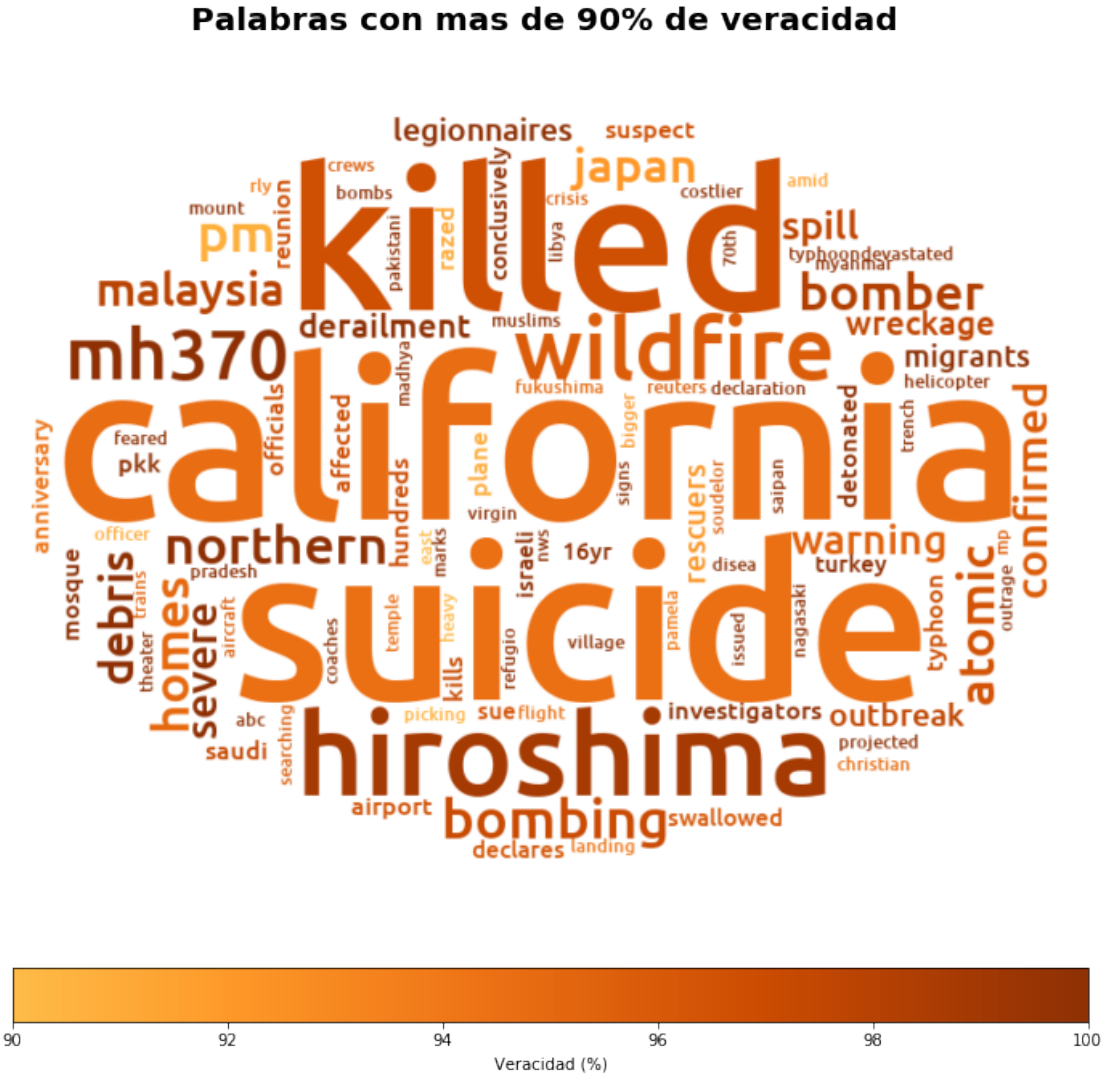

Ahora voy a analisar, las palabras que tienden a ser menos veraces.

[94]:
```
agrupadas_short = agrupadas.loc[agrupadas[('porcentaje_veraces')]==0,:]
agrupadas_short.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 2 entries, aftershock to lmao
Data columns (total 4 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   apariciones_veraces  2 non-null      int64
 1   apariciones_falaces  2 non-null      int64
```

```
 2   apariciones_totales  2 non-null      int64
 3   porcentaje_veraces   2 non-null      float64
dtypes: float64(1), int64(3)
memory usage: 80.0+ bytes
```

[95]:
```
saltos = np.linspace(0.3, 0.5, 2)
colores = cmap(saltos)

maximo = agrupadas_short['apariciones_totales'].max()

grafico = agrupadas_short.sort_values("apariciones_totales").plot(kind='barh',␣
 ↪figsize=(10,7), y ='apariciones_totales', color=colores, width=0.75,␣
 ↪fontsize = 18)

plt.xticks(np.arange(0, maximo+1, 2))
plt.tick_params(axis='y', length=0)

grafico.spines['right'].set_visible(False)
grafico.spines['top'].set_visible(False)
grafico.spines['left'].set_visible(False)
grafico.spines['bottom'].set_visible(False)

lineas = grafico.get_xticks()
for i in lineas:
      grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')

grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)

plt.title("Apariciones de palabras con 0% de veracidad", weight='bold',␣
 ↪size=20, pad=15)
```

[95]:
```
Text(0.5, 1.0, 'Apariciones de palabras con 0% de veracidad')
```

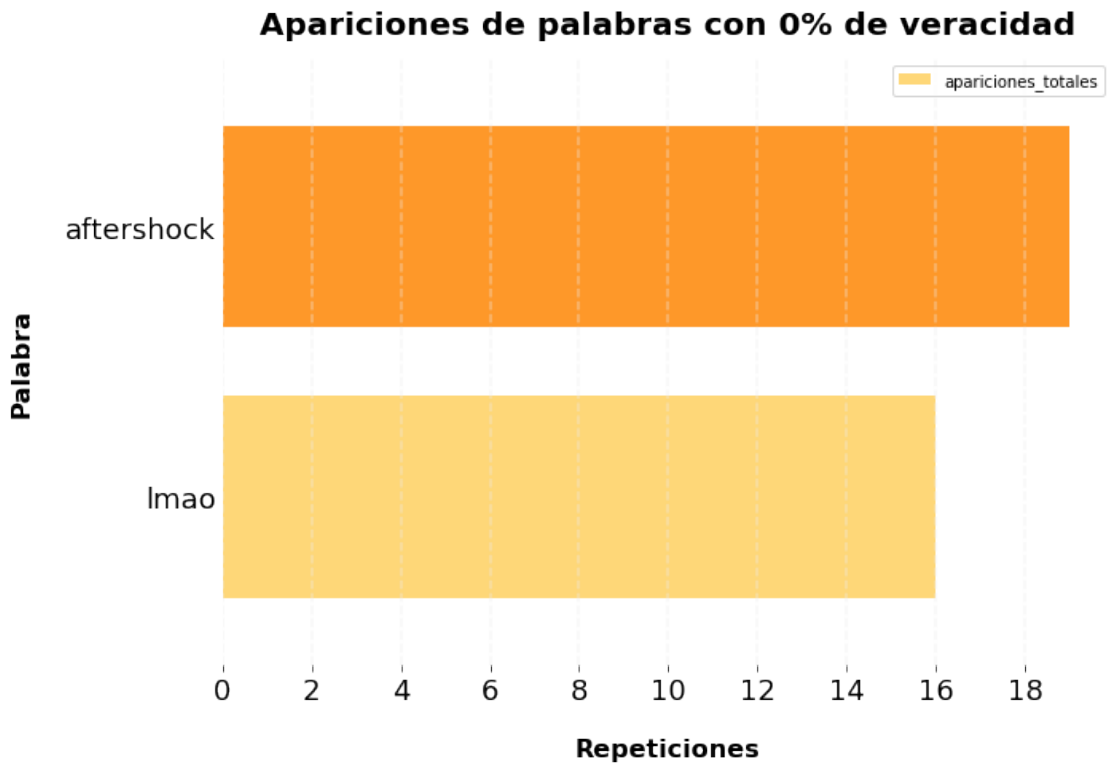

[96]:
```
agrupadas_short = agrupadas.loc[agrupadas[('porcentaje_veraces')]<=5,:]
agrupadas_short.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 11 entries, mayhem to lmao
Data columns (total 4 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   apariciones_veraces  11 non-null     int64
 1   apariciones_falaces  11 non-null     int64
 2   apariciones_totales  11 non-null     int64
 3   porcentaje_veraces   11 non-null     float64
dtypes: float64(1), int64(3)
memory usage: 440.0+ bytes
```

[97]:
```
saltos = np.linspace(0.3, 0.8, 13)
colores = cmap(saltos)

maximo = agrupadas_short['apariciones_totales'].max()

grafico = agrupadas_short.sort_values("apariciones_totales").plot(kind='barh',␣
 ↪figsize=(20,14), y ='apariciones_totales', color=colores, width=0.75,␣
 ↪fontsize = 18)
```

```
plt.xticks(np.arange(0, maximo+1, 2))
plt.tick_params(axis='y', length=0)

grafico.spines['right'].set_visible(False)
grafico.spines['top'].set_visible(False)
grafico.spines['left'].set_visible(False)
grafico.spines['bottom'].set_visible(False)

lineas = grafico.get_xticks()
for i in lineas:
      grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')

grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)

plt.title("Apariciones de palabras por debajo del 5% de veracidad",␣
 ↪weight='bold', size=20, pad=15)
plt.gca().get_legend().remove()
```

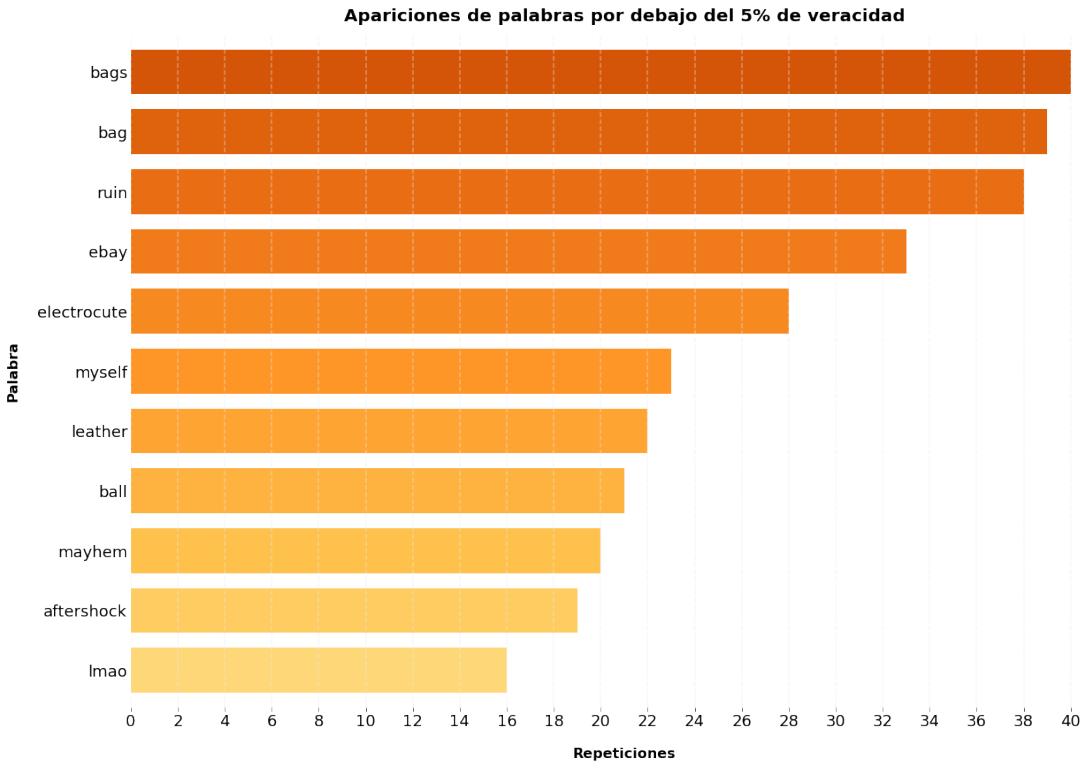

Estudiemos el 10%, buscando mas palabras

[98]:
```
agrupadas_short = agrupadas.loc[agrupadas[('porcentaje_veraces')]<=10,:]
agrupadas_short.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 37 entries, explode to lmao
Data columns (total 4 columns):
 #   Column               Non-Null Count  Dtype  
---  ------               --------------  -----  
 0   apariciones_veraces  37 non-null     int64  
 1   apariciones_falaces  37 non-null     int64  
 2   apariciones_totales  37 non-null     int64  
 3   porcentaje_veraces   37 non-null     float64
dtypes: float64(1), int64(3)
memory usage: 1.4+ KB
```

Tengo 37 elementos por debajo del 10%, hago un bar plot.

[99]:
```
saltos = np.linspace(0.3, 0.88, 41)
colores = cmap(saltos)

def my_tf_color_func_mayor_veracidad(dictionary):
  def my_tf_color_func_inner(word, font_size, position, orientation,␣
 ↪random_state=None, **kwargs):
    return colores_rgb[int ( dictionary[word]*4) ]
  return my_tf_color_func_inner


maximo = agrupadas_short['apariciones_totales'].max()

grafico = agrupadas_short.sort_values("apariciones_totales").plot(kind='barh',␣
 ↪figsize=(14,15), y ='apariciones_totales', color=colores, width=0.75,␣
 ↪fontsize = 18)

plt.xticks(np.arange(0, maximo+1, 5),rotation=35,fontsize=16,ha='right')
plt.tick_params(axis='y', length=0)

grafico.spines['right'].set_visible(False)
grafico.spines['top'].set_visible(False)
grafico.spines['left'].set_visible(False)
grafico.spines['bottom'].set_visible(False)

lineas = grafico.get_xticks()
for i in lineas:
      grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')

grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)
```

```
plt.title("Apariciones de palabras por debajo del 10% de veracidad",␣
 ↪weight='bold', size=20, pad=15)
plt.gca().get_legend().remove()
```

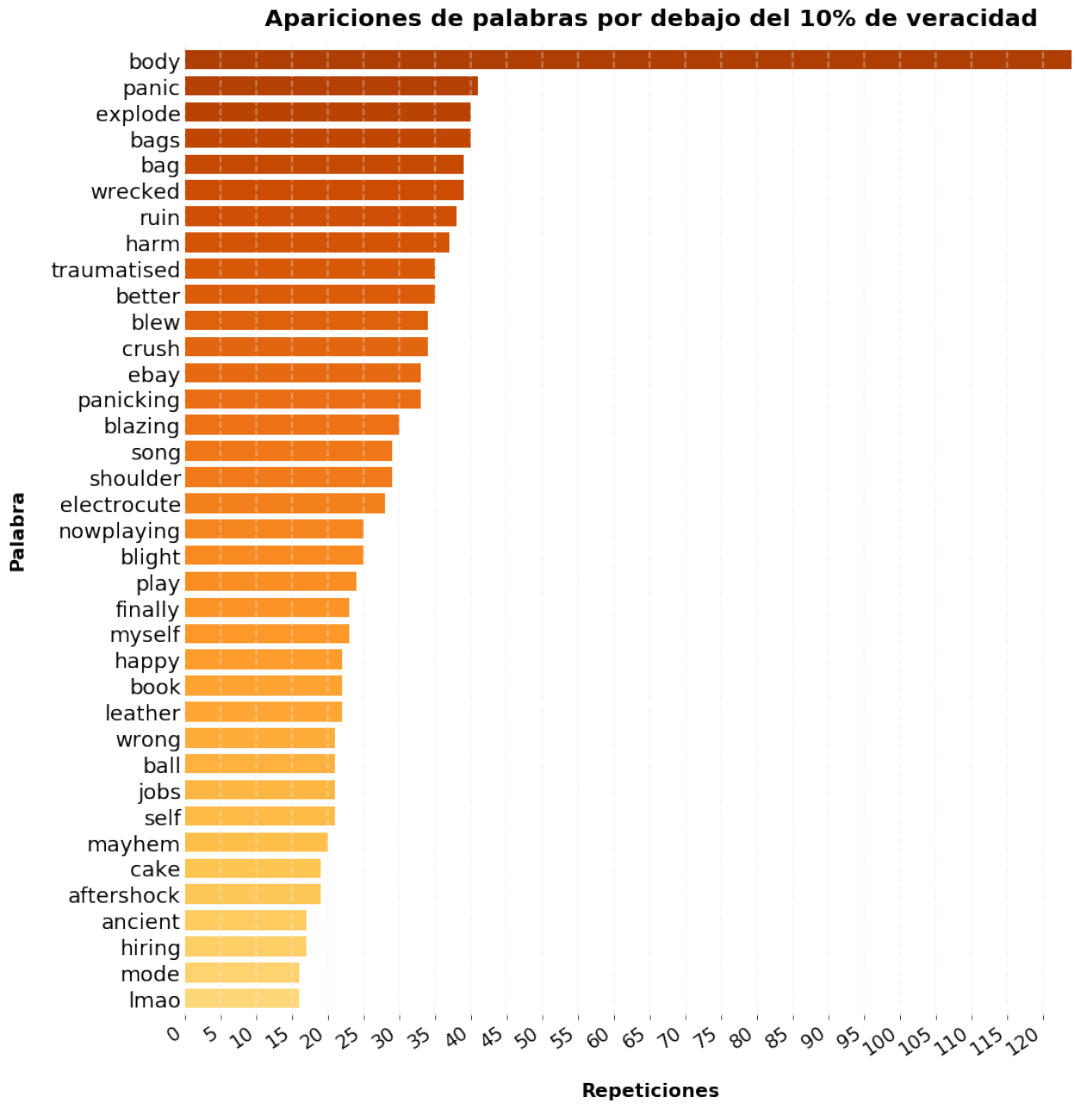

Palabras con 10% de apariciones

[100]:
```
indices = list(agrupadas_short.index)
valores = list(agrupadas_short['apariciones_totales'])
todas_las_palabras = list()

for i in range( len(indices) ):
    for j in range ( valores[i] ):
```

```
        todas_las_palabras.append(indices[i])

todas_las_palabras = pd.Series(todas_las_palabras).to_string()

keys = {}
veracidades = agrupadas_short['porcentaje_veraces'].tolist()

for i in range(len(indices)):
    keys[indices[i]] = veracidades[i]
```

[101]:
```
color_wordcloud = cmap(np.linspace(0.4, .9, 39))


plt.figure(figsize= (16,12) )
wordcloud = WordCloud(font_path='../fonts/truetype/ubuntu/Ubuntu-M.
 ↪ttf',collocations=False, colormap=cmap, \
                      relative_scaling=0.5, background_color='white',␣
 ↪width=800, height=200, \
                      color_func=my_tf_color_func_mayor_veracidad(keys),␣
 ↪normalize_plurals=False, mask=mask, prefer_horizontal=0.5).
 ↪generate(todas_las_palabras)

topes = mpl.colors.Normalize(vmin=0, vmax=10)
cmap_wordcloud = ListedColormap(cmap(np.linspace(0.4, 0.9, 256)))

plt.imshow(wordcloud, interpolation='bilinear')
plt.colorbar(cm.ScalarMappable(norm=topes, cmap=cmap_wordcloud),␣
 ↪label='Veracidad (%)', \
             orientation='horizontal', shrink=0.75, pad=0.05)
plt.axis("off")
plt.title("Palabras con menos de 10% de veracidad", weight='bold', size=20,␣
 ↪pad=30)
plt.show()
```

0.2.2 extra -> wordcloud de las palabras que mas se repiten

[102]:
```
agrupadas.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1037 entries, mh370 to lmao
Data columns (total 4 columns):
 #   Column               Non-Null Count  Dtype
---  ------               --------------  -----
 0   apariciones_veraces  1037 non-null   int64
 1   apariciones_falaces  1037 non-null   int64
 2   apariciones_totales  1037 non-null   int64
 3   porcentaje_veraces   1037 non-null   float64
```

```
dtypes: float64(1), int64(3)
memory usage: 80.5+ KB
```

[103]:
```
indices = list(agrupadas.index)
valores = list(agrupadas['apariciones_totales'])
todas_las_palabras = list()

for i in range( len(indices) ):
    for j in range ( valores[i] ):
        todas_las_palabras.append(indices[i])

todas_las_palabras = pd.Series(todas_las_palabras).to_string()
```

[104]:
```
len(todas_las_palabras)
```

[104]:
```
1788452
```

[105]:
```
type(STOPWORDS)
```

[105]:
```
set
```

[106]:
```
mask = np.array(Image.open("imagenes/twitter.jpg"))
wordcloud_bandera = WordCloud(stopwords=[""],␣
 ↪collocations=False,background_color="white", mode="RGBA", max_words=1000,␣
 ↪mask=mask, normalize_plurals=False).generate(todas_las_palabras)

image_colors = ImageColorGenerator(mask)
plt.figure(figsize=[14,14])
plt.imshow(wordcloud_bandera.recolor(color_func=image_colors),␣
 ↪interpolation="bilinear")
plt.axis("off")


plt.savefig("imagenes/palabras_con_wordstops.png", format="png")

plt.show()
```

filtrando por stopword (prepositions)

[107]:
```
mask = np.array(Image.open("imagenes/twitter.jpg"))
wordcloud_bandera = WordCloud(stopwords=STOPWORDS, collocations=False,background_color="white", mode="RGBA", max_words=1000, mask=mask, normalize_plurals=False).generate(todas_las_palabras)

image_colors = ImageColorGenerator(mask)
plt.figure(figsize=[14,14])
plt.imshow(wordcloud_bandera.recolor(color_func=image_colors), interpolation="bilinear")
plt.axis("off")


plt.savefig("imagenes/palabras_sin_wordstops.png", format="png")

plt.show()
```

0.2.3 longitud palabra promedio

[108]:
```
agrupadas.head()
```

[108]:

palabra	apariciones_veraces	apariciones_falaces	apariciones_totales	porcentaje_veraces
mh370	69	0	69	100.0
northern	64	0	64	100.0
debris	49	0	49	100.0
severe	44	0	44	
derailment	40	0	40	

```
severe                  100.0
derailment              100.0
```

[109]:
```
type(agrupadas.index[1])
```

[109]:
```
str
```

[110]:
```
agrupadas['largo'] = agrupadas.index.str.len()
```

[111]:
```
agrupadas.head()
```

[111]:
```
            apariciones_veraces  apariciones_falaces  apariciones_totales  \
palabra
mh370                        69                    0                   69
northern                     64                    0                   64
debris                       49                    0                   49
severe                       44                    0                   44
derailment                   40                    0                   40

            porcentaje_veraces  largo
palabra
mh370                    100.0      5
northern                 100.0      8
debris                   100.0      6
severe                   100.0      6
derailment               100.0     10
```

[112]:
```
color = cmap(0.7)
agrupadas.plot.scatter('largo','porcentaje_veraces', title='Relacion entre el␣
↪largo de una palabra y su veracidad',alpha=0.25,figsize=(16,10), color =␣
↪color);
ax=plt.gca()
ax.set_xlabel('Cantidad de caracteres')
ax.set_ylabel('Porcentaje de veracidad');
```

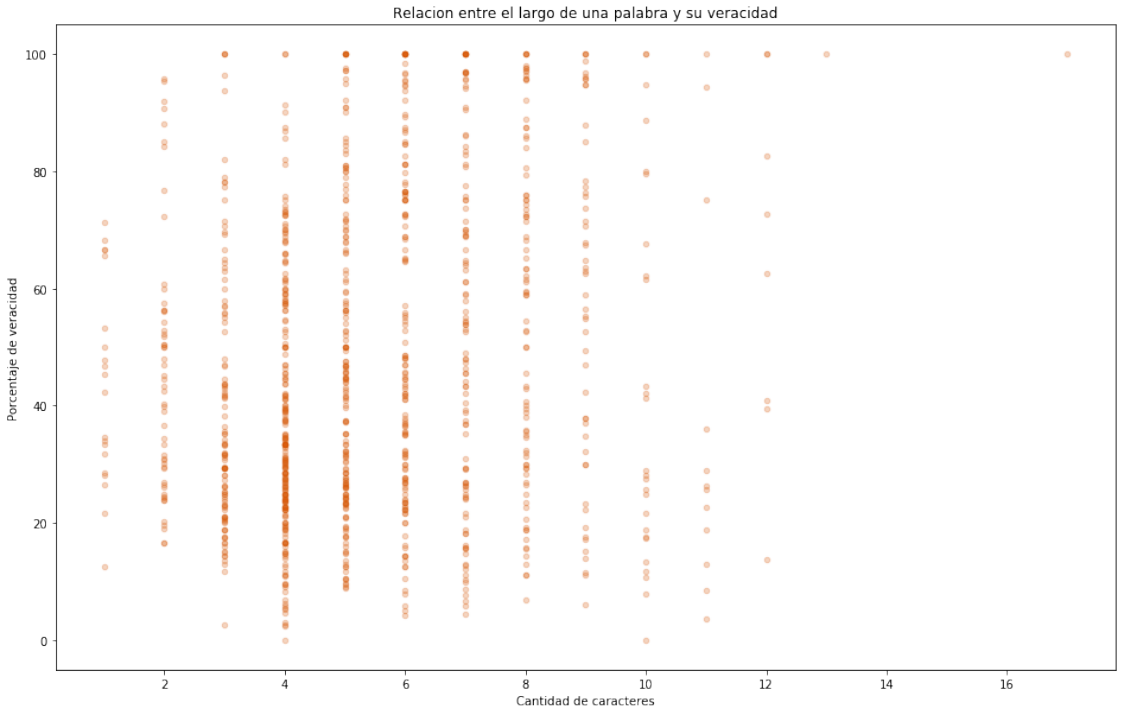

Ver la longitud promedio de las palabras

[113]:
```
tweets.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7613 entries, 0 to 7612
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   id            7613 non-null   int64
 1   text          7613 non-null   object
 2   palabras      7613 non-null   object
 3   nºcaracteres  7613 non-null   int64
 4   nºpalabras    7613 non-null   int64
 5   target        7613 non-null   int64
dtypes: int64(4), object(2)
memory usage: 357.0+ KB
```

[114]:
```
tweets.head()
```

[114]:

	id	text	\
0	1	Our Deeds are the Reason of this #earthquake M…	
1	4	Forest fire near La Ronge Sask. Canada	
2	5	All residents asked to 'shelter in place' are …	

```
3   6  13,000 people receive #wildfires evacuation or…
4   7  Just got sent this photo from Ruby #Alaska as …

                                          palabras  nºcaracteres  \
0  [Our, Deeds, are, the, Reason, of, this, #eart…            69
1     [Forest, fire, near, La, Ronge, Sask., Canada]            38
2  [All, residents, asked, to, 'shelter, in, plac…           133
3  [13,000, people, receive, #wildfires, evacuati…            65
4  [Just, got, sent, this, photo, from, Ruby, #Al…            88

   nºpalabras  target
0          13       1
1           7       1
2          22       1
3           8       1
4          16       1
```

[115]:
```
tweets['long_promedio_palabra'] = (tweets['nºcaracteres']/tweets['nºpalabras'])
```

[116]:
```
tweets.sample(3)
```

[116]:
```
         id                                               text  \
7307  10457  @SenFeinstein   Thanks Sen. Feinstein now hurr…
2720   3906  Obama declares disaster for typhoon-devastated…
5313   7587  Families to sue over Legionnaires: More than 4…

                                          palabras  nºcaracteres  \
7307  [@SenFeinstein, Thanks, Sen., Feinstein, now, …           139
2720  [Obama, declares, disaster, for, typhoon-devas…           136
5313  [Families, to, sue, over, Legionnaires:, More,…           136

      nºpalabras  target  long_promedio_palabra
7307          20       1               6.950000
2720          15       1               9.066667
5313          19       1               7.157895
```

[117]:
```
long_promedio = tweets['long_promedio_palabra'].mean()
long_promedioV = (tweets.loc[tweets['target'] == 1])['long_promedio_palabra'].
 ↪mean()
long_promedioF = (tweets.loc[tweets['target'] == 0])['long_promedio_palabra'].
 ↪mean()
```

[118]:
```
print([long_promedio, long_promedioV, long_promedioF])
```

```
[7.073938103684317, 7.425128783457523, 6.809372301395475]
```

[119]:
```
plt.figure(figsize= (12,6))

ax = plt.subplot()

# Example data
labels = ('Todos los tweets', 'Tweets verdaderos', 'Tweets falsos',)
y_pos = np.arange(len(labels))
promedio = [long_promedio, long_promedioV, long_promedioF]

ax.barh(y_pos, promedio, align='center', color = cmap([0.6,0.75,0.45]))
ax.set_yticks(y_pos)
ax.set_yticks(y_pos)
ax.set_yticklabels(labels)

plt.xticks(np.arange(0, 7.5, step=0.2), rotation=35,fontsize=10,ha='right')

lineas = ax.get_xticks()
for i in lineas:

      ax.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')

ax.invert_yaxis()
ax.set_xlabel('Largo promedio de palabra ( en caracteres)')
ax.set_title('Relacion entre largo de las palabras y veracidad del tweets')
```

[119]: Text(0.5, 1.0, 'Relacion entre largo de las palabras y veracidad del tweets')