Wordclouds de Banderas

May 21, 2020

```
[1]: import pandas as pd
     import numpy as np
     import matplotlib.pyplot as plt
     import seaborn as sns
     import matplotlib.cm as cm
     from bokeh.plotting import figure, output_file, show
     from bokeh.io import export_png
     from bokeh.io.export import get_screenshot_as_png
     from bokeh.plotting import figure, output_file, show
     from matplotlib.colors import ListedColormap
     import numpy as np
     import pandas as pd
     from os import path
     from PIL import Image
     from wordcloud import WordCloud, STOPWORDS, ImageColorGenerator
     import re
     import matplotlib.pyplot as plt
     cmap = cm.get_cmap('YlOrBr')
```

```
[2]: stopwords = set(STOPWORDS)
```

- 0.0.1 Gracias a analisis previos (En el analisis por ubicacion), sabemos que los paises con mas tweets son Estados Unidos, Reino Unido, Canada, Australia e india.
- 0.0.2 Grafico cuales son las palabras mas nombradas en dichos paises.

```
[3]: def generar_palabras(pais):
    tweets = pd.read_csv('../TP1-Organizacion-de-Datos/csv/train.csv')
    ciudades = pd.read_csv('../TP1-Organizacion-de-Datos/csv/worldcities.csv')
    la_ciudad_es_del_pais = ciudades.loc[:, 'country'].str.contains(pais, regex

→= False)
    ciudades_del_pais = ciudades.loc[la_ciudad_es_del_pais]
    ciudades_del_pais = ciudades_del_pais.reset_index(drop = True)
```

```
tweets_pais = pd.DataFrame()
  tweets_aux = pd.DataFrame()
  tweet_es_de_la_ciudad = pd.DataFrame()
  for x in range(ciudades_del_pais['city_ascii'].count()):
      ciudad = ciudades_del_pais.loc[x, 'city_ascii']
      if len(ciudad) > 4:
          tweet_es_de_la_ciudad = tweets.loc[:, 'location'].str.
else:
          tweet_es_de_la_ciudad = (tweets.loc[:, 'location'] == ciudad)
      tweets_aux = tweets.loc[tweet_es_de_la_ciudad]
      frames = [tweets_aux, tweets_pais]
      tweets_pais = pd.concat(frames)
  tweets_pais = tweets_pais.reset_index(drop = True)
  tweets pais['palabras'] = tweets pais['text'].str.split()
  palabras = tweets_pais['palabras'].explode()
  palabras = palabras.str.lower()
  palabras_limpias = []
  for palabra in palabras: #saco caracteres especiales
      palabra_limpia = re.sub('[^A-Za-z0-9]+','', palabra)
      palabras_limpias.append(palabra_limpia)
  palabras = []
  for w in palabras_limpias:
      if w not in stopwords:
          palabras.append(w)
  palabras = pd.Series(palabras)
  return (palabras)
```

0.1 Canada

Grafico palabras mas usadas en Canada

```
[4]: palabras = pd.DataFrame()

[5]: palabras ['palabra'] = generar_palabras("Canada")
```

agrupo

```
[6]: palabras = palabras.groupby(palabras.columns.tolist(),as_index=False).size()
```

Voy a graficar las primeras 10 palabras

```
[7]: palabras.sort_values(ascending = False, inplace = True)
palabras.head(10)
```

[7]: palabra

	56
emergency	13
new	11
one	10
us	9
injuries	9
mudslide	9
now	9
last	8
fire	8
dtype: int64	

Dropeo el espacio en blanco.

```
[8]: palabras = palabras.drop(labels =[""])
palabras.head(10)
```

[8]: palabra

```
emergency
             13
new
             11
one
             10
              9
us
injuries
               9
mudslide
               9
               9
now
last
               8
fire
               8
fires
dtype: int64
```

Filtro y me quedo con los primeros 10

```
[9]: palabras = palabras.head(10)
palabras
```

[9]: palabra emergency 13

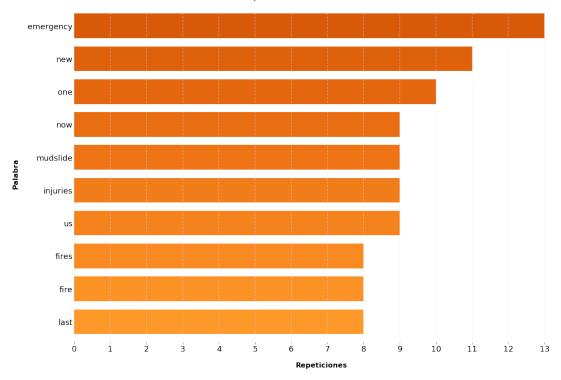
```
10
      one
     us
                    9
      injuries
     mudslide
     now
                    9
     last
                    8
     fire
                    8
      fires
      dtype: int64
[10]: saltos = np.linspace(0.5, 0.7, 10)
      colores = cmap(saltos)
      maximo = palabras.max()
      grafico = palabras.sort_values().plot(kind='barh', figsize=(20,14),__
      ⇔color=colores, width=0.75, fontsize = 18)
      plt.xticks(np.arange(0, maximo+1, 1))
      plt.tick_params(axis='y', length=0)
      grafico.spines['right'].set_visible(False)
      grafico.spines['top'].set_visible(False)
      grafico.spines['left'].set_visible(False)
      grafico.spines['bottom'].set_visible(False)
      lineas = grafico.get_xticks()
      for i in lineas:
            grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')
      grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
      grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)
      plt.title("Diez palabras mas usadas en Canada", weight='bold', size=20, pad=15)
```

[10]: Text(0.5, 1.0, 'Diez palabras mas usadas en Canada')

11

new





0.1.1 Grafico el cloud







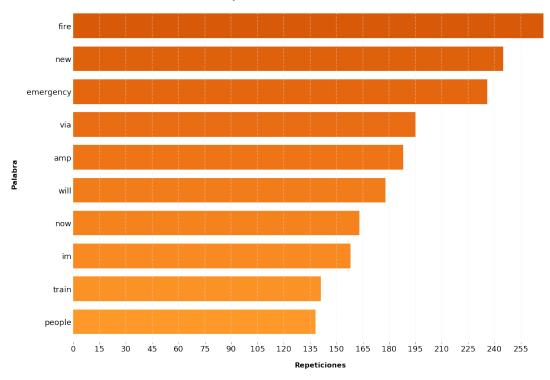
0.1.2 Ahora hago lo mismo con Estados Unidos

```
[13]: palabras = pd.DataFrame()
      palabras ['palabra'] = generar_palabras("United States")
[14]: palabras = palabras.groupby(palabras.columns.tolist(),as_index=False).size()
[15]: palabras.sort_values(ascending = False, inplace = True)
      palabras = palabras.drop(labels =[""])
      palabras.head(10)
[15]: palabra
     fire
                   268
                   245
     new
      emergency
                   236
     via
                   195
                   188
      amp
      will
                   178
                   163
     now
                   158
      im
      train
                   141
      people
                   138
      dtype: int64
```

```
[16]: palabras = palabras.head(10)
[17]: saltos = np.linspace(0.5, 0.7, 10)
      colores = cmap(saltos)
      maximo = palabras.max()
      grafico = palabras.sort_values().plot(kind='barh', figsize=(20,14),__
       ⇒color=colores, width=0.75, fontsize = 18)
      plt.xticks(np.arange(0, maximo+1, 15))
      plt.tick_params(axis='y', length=0)
      grafico.spines['right'].set_visible(False)
      grafico.spines['top'].set_visible(False)
      grafico.spines['left'].set_visible(False)
      grafico.spines['bottom'].set_visible(False)
      lineas = grafico.get_xticks()
      for i in lineas:
            grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')
      grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
      grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)
      plt.title("Diez palabras mas usadas en Estados Unidos", weight='bold', size=20, __
       →pad=15)
```

[17]: Text(0.5, 1.0, 'Diez palabras mas usadas en Estados Unidos')

Diez palabras mas usadas en Estados Unidos



```
makes surface value when now jobs wake anthrax is a part of the pa
```

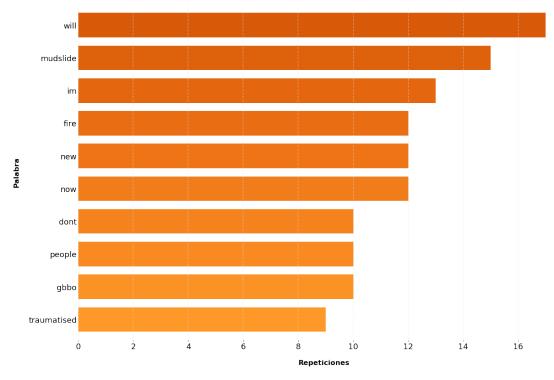
0.1.3 Ahora Reino Unido

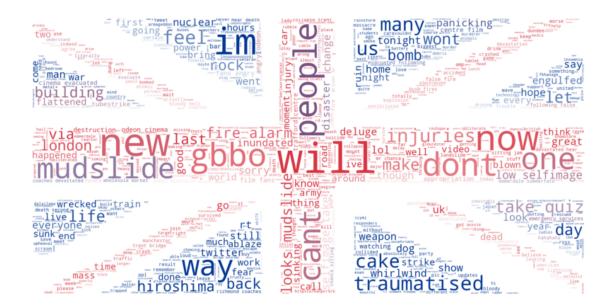
```
[20]: palabras = pd.DataFrame()
      palabras ['palabra'] = generar_palabras("United Kingdom")
[21]: palabras = palabras.groupby(palabras.columns.tolist(),as_index=False).size()
      palabras.sort_values(ascending = False, inplace = True)
      palabras = palabras.drop(labels =[""])
      palabras.head(10)
[21]: palabra
      will
                     17
     mudslide
                     15
      im
                     13
                     12
      now
                     12
      new
      fire
                     12
      gbbo
                     10
                     10
      people
                     10
      dont
      traumatised
                      9
      dtype: int64
[22]: palabras = palabras.head(10)
```

```
[23]: saltos = np.linspace(0.5, 0.7, 10)
      colores = cmap(saltos)
      maximo = palabras.max()
      grafico = palabras.sort_values().plot(kind='barh', figsize=(20,14),__
      ⇒color=colores, width=0.75, fontsize = 18)
      plt.xticks(np.arange(0, maximo+1, 2))
      plt.tick_params(axis='y', length=0)
      grafico.spines['right'].set_visible(False)
      grafico.spines['top'].set_visible(False)
      grafico.spines['left'].set_visible(False)
      grafico.spines['bottom'].set_visible(False)
      lineas = grafico.get_xticks()
      for i in lineas:
            grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')
      grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
      grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)
      plt.title("Diez palabras mas usadas en El Reino Unido", weight='bold', size=20,
       →pad=15)
```

[23]: Text(0.5, 1.0, 'Diez palabras mas usadas en El Reino Unido')

Diez palabras mas usadas en El Reino Unido



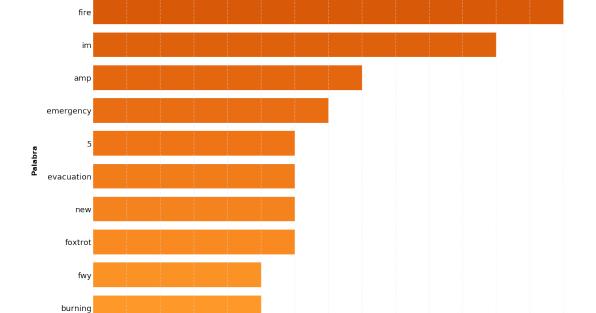


0.1.4 Australia

```
[25]: palabras = pd.DataFrame()
      palabras ['palabra'] = generar_palabras("Australia")
      palabras = palabras.groupby(palabras.columns.tolist(),as_index=False).size()
      palabras.sort_values(ascending = False, inplace = True)
      palabras = palabras.drop(labels =[""])
      palabras.head(10)
[25]: palabra
      fire
                    14
                    12
      im
                     8
      amp
                     7
      emergency
      foxtrot
                     6
      new
                     6
      evacuation
                     6
                     6
                     5
      burning
      fwy
      dtype: int64
[26]: palabras = palabras.head(10)
[27]: saltos = np.linspace(0.5, 0.7, 10)
      colores = cmap(saltos)
```

```
maximo = palabras.max()
grafico = palabras.sort_values().plot(kind='barh', figsize=(20,14),__
⇒color=colores, width=0.75, fontsize = 18)
plt.xticks(np.arange(0, maximo+1, 1))
plt.tick_params(axis='y', length=0)
grafico.spines['right'].set_visible(False)
grafico.spines['top'].set_visible(False)
grafico.spines['left'].set_visible(False)
grafico.spines['bottom'].set_visible(False)
lineas = grafico.get_xticks()
for i in lineas:
      grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')
grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)
plt.title("Diez palabras mas usadas en Australia", weight='bold', size=20, ___
 →pad=15)
```

[27]: Text(0.5, 1.0, 'Diez palabras mas usadas en Australia')

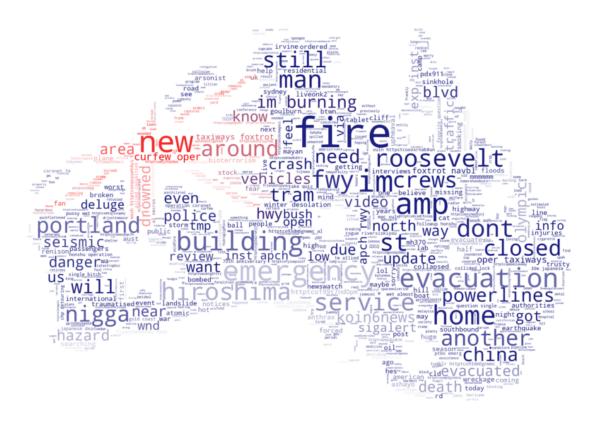


Diez palabras mas usadas en Australia

Repeticiones

10

11



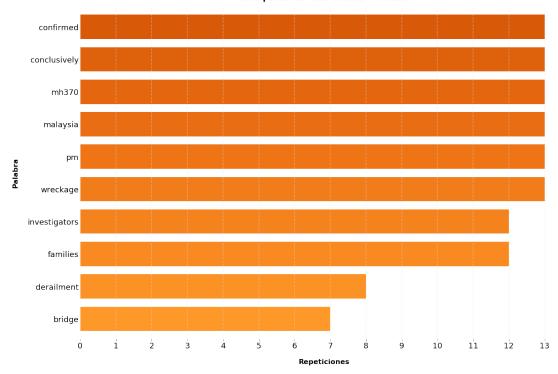
0.1.5 India

```
[29]: palabras = pd.DataFrame()
      palabras ['palabra'] = generar_palabras("India")
      palabras = palabras.groupby(palabras.columns.tolist(),as_index=False).size()
      palabras.sort_values(ascending = False, inplace = True)
      palabras = palabras.drop(labels =[""])
      palabras.head(10)
[29]: palabra
     wreckage
                       13
     pm
                       13
     malaysia
                       13
     mh370
                       13
      conclusively
                       13
      confirmed
                       13
      families
                       12
      investigators
                       12
      derailment
                        8
                        7
      bridge
      dtype: int64
[30]: palabras = palabras.head(10)
[31]: saltos = np.linspace(0.5, 0.7, 10)
      colores = cmap(saltos)
      maximo = palabras.max()
      grafico = palabras.sort_values().plot(kind='barh', figsize=(20,14),__
      ⇒color=colores, width=0.75, fontsize = 18)
      plt.xticks(np.arange(0, maximo+1, 1))
      plt.tick_params(axis='y', length=0)
      grafico.spines['right'].set_visible(False)
      grafico.spines['top'].set_visible(False)
      grafico.spines['left'].set_visible(False)
      grafico.spines['bottom'].set_visible(False)
      lineas = grafico.get xticks()
      for i in lineas:
            grafico.axvline(x=i, linestyle='--', alpha=0.4, color='#eeeeee')
      grafico.set_xlabel("Repeticiones", labelpad=20, weight='bold', size=16)
      grafico.set_ylabel("Palabra", labelpad=20, weight='bold', size=16)
```

```
plt.title("Diez palabras mas usadas en India", weight='bold', size=20, pad=15)
```

[31]: Text(0.5, 1.0, 'Diez palabras mas usadas en India')

Diez palabras mas usadas en India





pakistani
new statashur horror
wisagospel mumbai
httptcoog2jokd7sv

"trent bridge
nuchampur terror
keplegendary
achedin link
tasbookildustjanshursten
officials



[]: